UNIVERSIDAD MAYOR DE SAN ANDRÉS
CARRERA DE INFORMÁTICA

MINERÍA DE DATOS

DAT-254

Limpieza y auditoría de la Encuesta de Hogares 2024 de Bolivia

Estudiante: Imanol Marcelo Moya Condori

Docente: M. Sc. Menfy Morales Rios

Fecha: 4 de octubre de 2026

LA PAZ - BOLIVIA

2026

Resumen

Este informe documenta la limpieza de la base de datos *persona* de la Encuesta de Hogares 2024 del Instituto Nacional de Estadística de Bolivia (39.497 personas, 275 variables y 6.261.409 celdas vacías, 57,6%). El trabajo se organizó en seis bloques (global, vivienda, salud, educación, empleo e ingresos, y cierre) y 33 scripts en R, con una bitácora de operaciones, 33 informes técnicos y 6 resúmenes, 17 figuras y control de versiones en GitHub. El criterio central fue distinguir los vacíos estructurales, en que la pregunta no correspondía a la persona, de los reales, en que debía responder y no lo hizo. Se recodificaron a cero 42.459 celdas estructurales de escolaridad, horas e ingreso laboral, se reconstruyó el tamaño del hogar, que figuraba como 1 en 39.477 filas, y se corrigió un diccionario con tres columnas permutadas. Se imputaron 2.490 ingresos laborales con *predictive mean matching* y se recalcularon el ingreso y la pobreza del hogar, que pasó de 37,8% a 32,3% (sin ponderar). Una verificación posterior contra la base original mostró que 2.389 de esas imputaciones (95,9%) corresponden a dos categorías ocupacionales que casi no declaran ingreso por diseño del cuestionario, y que restringir la imputación a los demás casos devuelve la pobreza a 37,6%. Se concluye que clasificar el origen de cada vacío es más importante que imputarlo, y que la imputación de ingresos debe rehacerse antes de usar la base para estimar pobreza.

Palabras clave: limpieza de datos, valores faltantes, imputación, encuesta de hogares, pobreza, Bolivia.

Índice general

1. Introducción 8
1.1 Planteamiento del problema 8
1.2 Justificación 8
1.3 Alcance y delimitación 9

2. Objetivos 10
2.1 Objetivo general 10
2.2 Objetivos específicos 10

3. Marco teórico 11
3.1 Datos, información y conocimiento 11
3.2 Minería de datos y proceso de descubrimiento 11
3.3 Tipos de datos y atributos 12
3.4 Calidad de datos y limpieza 12
3.5 Valores faltantes 13
3.6 Imputación por emparejamiento de medias predictivas 14
3.7 Valores atípicos y acotamiento 15
3.8 Variables derivadas e identidades contables 15
3.9 Encuestas de hogares, pobreza y la EH 2024 15
3.10 Reproducibilidad y control de versiones 16

4. Marco metodológico 17
4.1 Fuente de datos 17
4.2 Herramientas 18
4.3 Arquitectura del proyecto 18
4.4 El ciclo de cada script 19
4.5 El árbol de decisión de la limpieza 20
4.6 Convención de nombres de variables 21
4.7 Antecedente: la primera versión del Bloque 0 21

5. Desarrollo: el recorrido 22
5.1 Bloque 0 · Global (scripts 00 a 07) 22
5.2 Bloque 1 · Vivienda y hogar (scripts 08 a 11) 26
5.3 Bloque 2 · Salud (scripts 12 a 16) 28
5.4 Bloque 3 · Educación (scripts 17 a 21) 31
5.5 Bloque 4 · Empleo e ingresos laborales (scripts 22 a 27) 33
5.6 Bloque 5 · Ingresos no laborales y cierre (scripts 28 a 32) 39
5.7 Errores, discrepancias y correcciones del camino 41
5.8 Resultados globales y análisis de sensibilidad 42

6. El repositorio en GitHub 45
6.1 Qué contiene 45
6.2 Cómo se organiza el trabajo en Git 45
6.3 Cómo reproducirlo 46
6.4 Cómo leer y reutilizar los informes 46

7. Discusión **47**
8. Conclusiones **49**
9. Recomendaciones **50**
Referencias **51**
Apéndice A. Glosario **53**
Apéndice B. Variables trabajadas por bloque **54**
Apéndice C. Los 33 scripts, uno por uno **55**
Apéndice D. Extracto de la bitácora de limpieza **56**
Apéndice E. Hipótesis y reglas por confirmar con la boleta **57**
Apéndice F. Cómo reproducir el proyecto **58**
Apéndice G. Diccionario de datos completo de persona_limpio **59**

Índice de tablas

Tabla 1. Procesos de minería de datos y ubicación de este trabajo 11
Tabla 2. Tipos de datos y ejemplos de la base persona 12
Tabla 3. Las cinco fases de preprocesamiento de la bitácora y su aplicación 12
Tabla 4. Mecanismos de pérdida de datos 13
Tabla 5. Vacío estructural y vacío real 13
Tabla 6. Métodos de tratamiento de valores faltantes 14
Tabla 7. Columnas y vacíos por bloque temático: base original y base final 17
Tabla 8. Estructura de carpetas del proyecto 18
Tabla 9. Las doce columnas de la bitácora de limpieza 19
Tabla 10. Comparación entre la primera versión del Bloque 0 y la versión final 21
Tabla 11. Scripts del Bloque 0 (global) 22
Tabla 12. Correcciones al diccionario de datos 23
Tabla 13. Las nueve reglas de salto del cuestionario y el tamaño de cada universo 24
Tabla 14. Resultado del Bloque 0 26
Tabla 15. Identidades y reglas verificadas en el Bloque 1 28
Tabla 16. Preguntas de salud, universo y resultado del diagnóstico 29
Tabla 17. Preguntas de educación y su universo 31
Tabla 18. Qué explica los vacíos de empleo e ingresos y cómo se trataron 39
Tabla 19. Variables cuyo valor cambió entre la base original y la base final 40
Tabla 20. Discrepancias encontradas entre la documentación y los datos 41
Tabla 21. Celdas completadas en la base y método de relleno 42
Tabla 22. Tasas de pobreza según el tratamiento del ingreso laboral faltante 42
Tabla 23. Contenido del repositorio de GitHub 45
Tabla 24. Historial de commits del repositorio 45
Tabla 25. Glosario de términos 53
Tabla 26. Variables originales y variables añadidas por bloque 54
Tabla 27. Los 33 scripts del proyecto 55
Tabla 28. Primeras filas de la bitácora de limpieza 56
Tabla 29. Hipótesis y supuestos deducidos de los datos 57
Tabla 30. Pasos para reproducir el proyecto 58
Tabla 31. Diccionario de datos completo de la base persona_limpio (294 variables) 59

Índice de figuras

Figura 1. Porcentaje de celdas vacías por bloque en la base original y en la base final 18
Figura 2. Árbol de decisión aplicado a cada variable con celdas vacías 20
Figura 3. Distribución de columnas según el porcentaje de valores faltantes 23
Figura 4. Descomposición de los vacíos en estructurales y reales para las cuatro variables clasificadas 25
Figura 5. Distribución real del tamaño del hogar frente al aplanamiento original 27
Figura 6. Ingreso per cápita del hogar según condición de pobreza 28
Figura 7. Distribución de la cobertura de seguro de salud según los códigos de la base 30
Figura 8. Gasto de bolsillo en salud entre quienes declaran gasto 31
Figura 9. Años de estudio aprobados por grupo de edad en la población de 4 años o más 32
Figura 10. Años de estudio frente a edad con la cota biológica (edad menos 4) 32
Figura 11. Tasa de uso de internet por grupo de edad 33
Figura 12. Condición de actividad de la población 34
Figura 13. Horas trabajadas por semana entre los ocupados 35
Figura 14. Ingreso laboral observado frente a imputado con PMM 36
Figura 15. Ocupados de la PET sin ingreso laboral por categoría ocupacional, e imputaciones recibidas 37
Figura 16. Ingreso laboral mensual y Salario Mínimo Nacional 38
Figura 17. Ingreso laboral por hora según nivel de instrucción y sexo 38
Figura 18. Ingresos no laborales por grupo de edad 39
Figura 19. Ingreso per cápita del hogar y líneas de pobreza en la base final 40
Figura 20. Pobreza moderada y extrema según el tratamiento del ingreso laboral faltante 43

1. Introducción

Imaginemos que alguien nos entrega una tabla con casi cuarenta mil personas y 275 columnas. Cada fila es una persona que vive en Bolivia; cada columna, la respuesta a una pregunta sobre su salud, su escuela, su trabajo o su hogar. Al abrir el archivo descubrimos que más de la mitad de las celdas están vacías. La reacción más común es pensar que hay que rellenar todo eso. Este informe cuenta por qué esa reacción habría sido un error y qué se hizo en su lugar, incluyendo una parte que no salió como se esperaba y que se documenta con la misma franqueza que los aciertos.

La base se llama *persona* y proviene de la Encuesta de Hogares 2024 del Instituto Nacional de Estadística [INE] de Bolivia (INE, 2024). Es el insumo con el que se estudian la pobreza, el empleo, la educación y la salud de la población, de modo que sus errores no son menores: un ingreso mal calculado puede cambiar quién es considerado pobre. A lo largo del proyecto se escribieron 33 scripts y se registraron las operaciones en una bitácora de 12 columnas, todo dentro de un repositorio numerado y versionado en GitHub.

1.1 Planteamiento del problema

La base original presenta tres dificultades que se refuerzan entre sí. La primera es la cantidad de celdas vacías: 6.261.409 de 10.861.675, es decir, 57,6%. La segunda es que el diccionario de datos entregado junto con la base no describe lo que las columnas contienen: las variables *s01a_02*, *s01a_03* y *s01a_05* figuran como parentesco, sexo y edad, pero contienen sexo, edad y parentesco, y la columna *totper*, que debía contar a las personas del hogar, vale 1 en 39.477 de las 39.497 filas y está vacía en las otras 20. La tercera es que los indicadores derivados, como el ingreso del hogar y la condición de pobreza, dependen de columnas con vacíos: 22.788 ingresos laborales estaban vacíos y el ingreso individual se calculaba tratando esos vacíos como cero.

Frente a esto, la pregunta que guía el trabajo es: ¿qué celdas vacías son realmente datos perdidos y cuáles son preguntas que no correspondían a esa persona? Solo las primeras pueden, con cuidado, completarse. La segunda pregunta, que surgió al verificar el resultado, es qué tan sensible es la tasa de pobreza a la manera en que se completan los ingresos.

1.2 Justificación

La preparación de datos suele ser la parte más larga y menos visible de un proyecto analítico, y es donde se toman las decisiones que condicionan todo lo demás (Chapman et al., 2000; Fayyad et al., 1996). Cuando esas decisiones no quedan registradas, nadie puede auditarlas ni repetirlas. Este trabajo se justifica por tres razones: ofrece una respuesta metodológica a un problema real y frecuente en encuestas con saltos de cuestionario; deja trazabilidad de cada cambio mediante una bitácora, banderas de linaje en la propia base y checkpoints por script; y, al contrastar la base final con la original, muestra con cifras cómo una decisión de imputación puede mover un indicador oficial.

1.3 Alcance y delimitación

El estudio cubre la tabla *persona* de la gestión 2024 y se organiza en los cuatro temas pedidos por la asignatura (vivienda, salud, educación, y empleo e ingresos), más un bloque global previo y un bloque de cierre. No se construyeron modelos predictivos ni se calcularon estadísticas poblacionales: el producto es una base depurada y documentada. Tres límites condicionan las conclusiones. Primero, no se dispuso de la boleta oficial, por lo que algunas reglas se dedujeron de los datos y se declaran como hipótesis (Apéndice E). Segundo, las tasas que se informan se calculan sin ponderar, salvo cuando se indica lo contrario. Tercero, el pipeline final clasificó con indicadores explícitos solo cuatro variables (embarazo, escolaridad, horas e ingreso laboral); los demás vacíos se conservaron como vacíos.

El repositorio contiene además una primera versión del Bloque 0 (carpetas *scripts*, *informes* y *data*, ocho scripts), que dedujo reglas de salto para 229 variables. Esa versión no alimentó la base final; se describe como antecedente en la sección 4.7 porque sus hallazgos resultaron decisivos para evaluar el trabajo posterior.

2. Objetivos

2.1 Objetivo general

Depurar y documentar de manera reproducible la base *persona* de la Encuesta de Hogares 2024 de Bolivia, distinguiendo los vacíos estructurales de los reales, completando únicamente los valores cuyo origen y método de relleno puedan justificarse, y evaluando el efecto de esas decisiones sobre los indicadores de ingreso y pobreza.

2.2 Objetivos específicos

- Auditar la base y reconciliar el diccionario de datos con los valores observados.
- Clasificar las celdas vacías de las variables críticas como estructurales o reales, a partir de las reglas de salto del cuestionario.
- Tratar los bloques de vivienda, salud, educación y empleo e ingresos con reglas explícitas y validaciones automáticas.
- Completar los vacíos reales con una regla lógica o con imputación por *predictive mean matching*, y propagar el cambio a las variables derivadas.
- Crear variables derivadas y banderas de linaje que permitan distinguir el dato observado del dato intervenido.
- Registrar cada operación en una bitácora, en informes en Markdown y en un repositorio numerado que permita reproducir el proceso.
- Contrastar la base final con la original y medir cuánto cambian los indicadores de pobreza por efecto de la imputación.

3. Marco teórico

Este capítulo reúne los conceptos que sostienen el trabajo. Está escrito para que pueda leerse sin conocimientos previos, pero conserva la terminología.

3.1 Datos, información y conocimiento

Un dato es un registro aislado, como el número 71 en la columna *s01a_03*. Se convierte en información cuando sabemos qué significa (la edad de una persona) y en conocimiento cuando lo usamos para entender algo (en este hogar conviven un adulto mayor y un niño). La limpieza de datos opera en el primer escalón: asegura que cada número signifique lo que decimos que significa. Sin ese cuidado, todo lo que se construya encima hereda el error.

3.2 Minería de datos y proceso de descubrimiento

La minería de datos es el proceso de explorar y analizar grandes volúmenes de datos para extraer información implícita, previamente desconocida y potencialmente útil (Fayyad et al., 1996; Han et al., 2012). Para que un proyecto de datos no sea una colección de ocurrencias existen procesos estándar. El descubrimiento de conocimiento en bases de datos (KDD, por sus siglas en inglés) propone cinco etapas: selección, preprocesamiento, transformación, minería de datos y evaluación (Fayyad et al., 1996). La metodología CRISP-DM organiza el trabajo en seis fases cíclicas y reconoce expresamente que la preparación de los datos consume buena parte del esfuerzo (Chapman et al., 2000). La Tabla 1 ubica este trabajo dentro de ambos esquemas: casi todo ocurre en el preprocesamiento y la preparación, y la parte de "modelado" se reduce a la imputación de un solo campo.

Tabla 1
Procesos de minería de datos y ubicación de este trabajo

Etapa de KDD	Fase de CRISP-DM	En este trabajo
Selección	Comprensión de los datos	Elección de la base *persona*; auditoría inicial (script 00); reconciliación del diccionario (01)
Preprocesamiento	Preparación de los datos	Núcleo del informe: tipos, texto, integridad, reglas de salto, clasificación y tratamiento de vacíos (02 a 07 y bloques 1 a 5)
Transformación	Preparación de los datos	Variables derivadas: *gasto_salud_total*, *uso_internet*, *clima_educativo_hogar*, *ingreso_horario* y banderas de linaje
Minería de datos	Modelado	Solo la imputación de ingresos con *predictive mean matching* (script 24); no hay modelos predictivos

Etapa de KDD	Fase de CRISP-DM	En este trabajo
Evaluación	Evaluación	Aserciones por bloque, certificación global (script 32) y análisis de sensibilidad (sección 5.8)

Nota. Elaboración propia con base en Fayyad et al. (1996) y Chapman et al. (2000).

3.3 Tipos de datos y atributos

Antes de limpiar hay que saber qué clase de dato tiene cada columna, porque de ello depende qué operaciones tienen sentido. No se puede promediar un número de folio ni calcular la mediana de un departamento. La Tabla 2 resume los tipos presentes en la base.

Tabla 2
Tipos de datos y ejemplos de la base persona

Tipo	Descripción	Ejemplos
Identificador	Llave que distingue registros; no se opera aritméticamente	*folio*, *upm*, *estrato*, *nro* (llave compuesta *folio* + *nro*)
Nominal	Categorías sin orden	*depto*, *area*, *sexo*, *parentesco*
Ordinal	Categorías con orden	*s02a_04a* a *s02a_04f* (dificultad permanente, 1 a 4)
Numérico	Cantidades con cero significativo	*edad*, *aestudio*, *tothrs*, *ylab*, *yhogpc*
Binario	Dos valores posibles	*p0*, *pext0* y las banderas *_imputado*
Texto libre	Respuesta abierta	Las 14 columnas "e" (*s03a_05e*, *s04a_06e*, *s05a_02ce*…)

Nota. Elaboración propia con base en INE (2024).

3.4 Calidad de datos y limpieza

Un dato es de buena calidad si es completo, consistente, único y válido en relación con su uso (Han et al., 2012). La limpieza es el conjunto de operaciones que acerca los datos a esa condición sin cambiar su significado. En este proyecto la bitácora clasifica cada operación en una de cinco fases (Tabla 3), de modo que cualquier cambio puede ubicarse en el recorrido: se midió, se normalizó, se verificó la unicidad, se trataron los vacíos o se validó la consistencia.

Tabla 3
Las cinco fases de preprocesamiento de la bitácora y su aplicación

Fase	Qué se hace	Scripts
1. Auditoría y perfilado	Medir vacíos, tipos, rangos y universos antes de modificar nada	00, 08, 12, 17, 22, 28
2. Normalización de estructuras y formatos	Corregir el diccionario, convertir tipos, normalizar texto, reconstruir *totper*	01, 02, 03, 09

Fase	Qué se hace	Scripts
3. Gestión de duplicados	Verificar la llave primaria y la jefatura única del hogar	04
4. Diagnóstico y tratamiento de valores faltantes	Formalizar reglas de salto, clasificar y recodificar vacíos, imputar	05, 06, 07, 13, 15, 18, 23, 24, 29
5. Validación, enriquecimiento y cierre	Verificar consistencia, crear variables derivadas, aserciones y exportación	10, 11, 14, 16, 19 a 21, 25 a 27, 30 a 32

Nota. Elaboración propia con base en la columna *metodologia_fase* de la bitácora de limpieza.

3.5 Valores faltantes

Un valor faltante es una celda sin dato. Rubin (1976) distinguió tres mecanismos según qué determina que el dato falte, distinción que sigue siendo la base del tema (Little y Rubin, 2019). La Tabla 4 los resume.

Tabla 4
Mecanismos de pérdida de datos

Mecanismo	Qué significa	Ejemplo en la base	Consecuencia
MCAR (completamente al azar)	Faltar no depende de nada	Un error de captura aleatorio	Eliminar o imputar casi no sesga
MAR (al azar condicionado)	Faltar depende de variables observadas	Ingreso omitido con más frecuencia en cierta área o categoría	La imputación condicional es válida
MNAR (no al azar)	Faltar depende del propio valor	Ingresos altos que no se declaran	Requiere supuestos explícitos y análisis de sensibilidad

Nota. Elaboración propia con base en Rubin (1976) y Little y Rubin (2019).

En una encuesta con saltos de cuestionario aparece además una distinción que los tres mecanismos no cubren. Muchas preguntas se hacen solo a una parte de las personas (a las mujeres en edad fértil, a los ocupados, a los mayores de 60 años) y al resto se les salta la pregunta. Esas celdas están vacías por diseño. Llamamos **vacío estructural** a ese caso y **vacío real** al de quien debía responder y no lo hizo (Tabla 5). Solo el segundo es un dato perdido en sentido estricto.

> ***En palabras simples:*** si a una persona de 8 años no se le pregunta su sueldo, no hay sueldo que "recuperar". Rellenarlo con el promedio de los adultos sería inventar un dato. Si a un obrero se le pregunta su sueldo y no contesta, el dato existe pero falta, y ahí sí se puede estimar.

Tabla 5
Vacío estructural y vacío real

	Vacío estructural	**Vacío real**
Definición	La pregunta no correspondía a la persona	La persona debía responder y no lo hizo
Ejemplo	Horas trabajadas de un inactivo; embarazo en un hombre	Ingreso omitido por un asalariado
¿Es un dato perdido?	No: la información no existe	Sí
Tratamiento	Dejar vacío, codificar, o recodificar a 0 si es una magnitud	Regla lógica o imputación, con bandera de linaje
Riesgo de confundirlos	Imputar valores inexistentes	Dejar sesgo por no respuesta

Nota. Elaboración propia.

Existen varias maneras de tratar los valores faltantes reales. La Tabla 6 las compara e indica cuáles se usaron en el proyecto.

Tabla 6
Métodos de tratamiento de valores faltantes

Método	**Idea**	**Límite**	**Uso aquí**
Eliminar filas o columnas	Descartar lo incompleto	Pierde información y puede sesgar	No: se conservan las 39.497 filas
Valor lógico o constante	Asignar 0 o una categoría cuando el vacío tiene significado	Exige conocer la regla	Sí: 42.459 ceros
Media o mediana	Reemplazar por un estadístico del grupo	Reduce la varianza	Previsto en scripts 18 y 23; sin casos
Hot-deck	Copiar el valor de un donante parecido	Requiere definir grupos	Indirecto, vía PMM
Regresión	Predecir el valor con otras variables	Puede dar valores imposibles	No
PMM con mice	Predecir y tomar el valor real de un donante cercano	Sensible a los donantes; con una sola imputación no mide la incertidumbre	Sí: 2.490 ingresos

Nota. Elaboración propia con base en Little y Rubin (2019) y van Buuren (2018).

3.6 Imputación por emparejamiento de medias predictivas

La imputación múltiple por ecuaciones encadenadas (MICE) completa cada variable con vacíos usando un modelo que depende de las demás y repite el ciclo varias veces (van Buuren y Groothuis-Oudshoorn, 2011). El método *predictive mean matching* (PMM), atribuido a Rubin (1986) y Little (1988), funciona así: se ajusta una regresión con los casos observados, se calcula la predicción para todos, y para cada caso faltante se buscan los casos observados con predicción más cercana. De entre esos donantes se sorteó uno y se copia su valor real. La ventaja es que el

valor imputado siempre es un valor que existe en los datos, de modo que no aparecen ingresos negativos ni valores fuera de rango (van Buuren, 2018).

La imputación es "múltiple" cuando se generan varios conjuntos completos (parámetro *m*), se analiza cada uno y se combinan los resultados con las reglas de Rubin (1987), de manera que la incertidumbre de haber imputado quede reflejada en los errores estándar. Con $m = 1$ se obtiene una sola base completa: el método sigue siendo PMM, pero no es imputación múltiple en sentido estricto. Esta diferencia es relevante porque el proyecto usó $m = 1$ (sección 5.5). Un último punto, decisivo en este trabajo: PMM supone que el vacío es MAR, es decir, que la persona tiene un ingreso que no declaró. No es válido cuando el ingreso no existe.

3.7 Valores atípicos y acotamiento

Un valor atípico es el que se aleja de los demás. Una regla clásica es la de Tukey (1977), que marca como atípico lo que queda más allá de 1,5 veces el rango intercuartílico. En este proyecto se aplicó otro criterio, más sencillo: una cota física. Una semana tiene 168 horas y se asumió que nadie trabaja más de 16 horas diarias durante 7 días, es decir, 112 horas semanales. Lo que supera la cota se *acota* a 112 (*winsorización* con un límite externo). No se eliminan registros: se limita el valor, y el cambio queda registrado.

3.8 Variables derivadas e identidades contables

Una variable derivada se calcula a partir de otras. En una encuesta de hogares abundan, y entre ellas existen identidades que deben cumplirse siempre: el ingreso individual es la suma del ingreso laboral y el no laboral; el ingreso del hogar es la suma de los ingresos de sus miembros; y el ingreso per cápita es el del hogar dividido entre el número de personas. Si se corrige una pieza (por ejemplo, un ingreso imputado) hay que propagar el cambio en cadena. Verificar estas identidades es un control de integridad barato y potente.

3.9 Encuestas de hogares, pobreza y la EH 2024

Las encuestas de hogares recogen información de una muestra de viviendas y sus habitantes con un cuestionario organizado en secciones. La Encuesta de Hogares 2024 del INE de Bolivia incluye secciones de demografía, salud, educación, empleo e ingresos (INE, 2024). La pobreza se mide por ingresos: un hogar es pobre moderado si su ingreso per cápita (*yhogpc*) es menor que la línea de pobreza (*z*) y pobre extremo si es menor que la línea de pobreza extrema (*zext*). Las tasas

resultantes son casos del índice de recuento de la familia de medidas de Foster et al. (1984), y por definición todo pobre extremo es también pobre moderado. En la base, *p0* y *pext0* son los indicadores binarios de ambas condiciones.

Dos referencias normativas aparecen en el trabajo. La Renta Dignidad, pensión universal no contributiva, se cobra desde los 60 años (Ley 3791). El Salario Mínimo Nacional de la gestión 2024 es de Bs 2.500, fijado por el Decreto Supremo 5154 de 1 de mayo de 2024. La jornada legal es de 48 horas semanales. Por último, la encuesta incluye un factor de expansión (*factor*) que permite proyectar la muestra a la población; las tasas sin ponderar describen la muestra, no el país.

3.10 Reproducibilidad y control de versiones

Un análisis es reproducible si otra persona, con los mismos datos y el mismo código, obtiene los mismos resultados (Sandve et al., 2013). Para lograrlo conviene numerar los pasos, guardar el estado intermedio, registrar cada operación y versionar el código. Git permite conservar el historial de cambios y GitHub lo publica. Estas prácticas son coherentes con los principios de que los datos y su documentación sean localizables, accesibles, interoperables y reutilizables (Wilkinson et al., 2016).

4. Marco metodológico

4.1 Fuente de datos

Se trabajó con el archivo *persona.csv* de la Encuesta de Hogares 2024 del INE, que contiene 39.497 filas (una por persona) y 275 columnas, y con el archivo *Diccionario de Persona*. Las personas pertenecen a 12.718 hogares, con un promedio de 3,11 miembros. Hay 20.040 mujeres y 19.457 hombres; 30.103 personas viven en área urbana y 9.394 en área rural; la edad va de 0 a 98 años, con media de 32,0. La llave primaria es la pareja (*folio, nro*). Se clasificaron las columnas en seis bloques temáticos (Tabla 7). La base tiene 57,6% de celdas vacías, concentradas en Empleo (78,2%) porque sus preguntas se dirigen solo a los ocupados (Figura 1).

Conviene aclarar qué representa cada fila. La unidad de análisis es la persona, pero las personas viven en hogares y varias columnas describen al hogar y no a la persona: *totper*, *yhog*, *yhogpc*, *z*, *zext*, *p0* y *pext0* se repiten idénticas en todas las filas de un mismo *folio*. Por eso, al contar "personas pobres" se cuenta a las personas que viven en hogares pobres, y por eso un cambio en el ingreso de una sola persona (por ejemplo, una imputación) modifica el ingreso y la clasificación de pobreza de todo su hogar. Esta propiedad explica por qué 2.239 ingresos individuales cambiados terminaron alterando 7.326 ingresos de hogar (sección 5.6).

Tabla 7

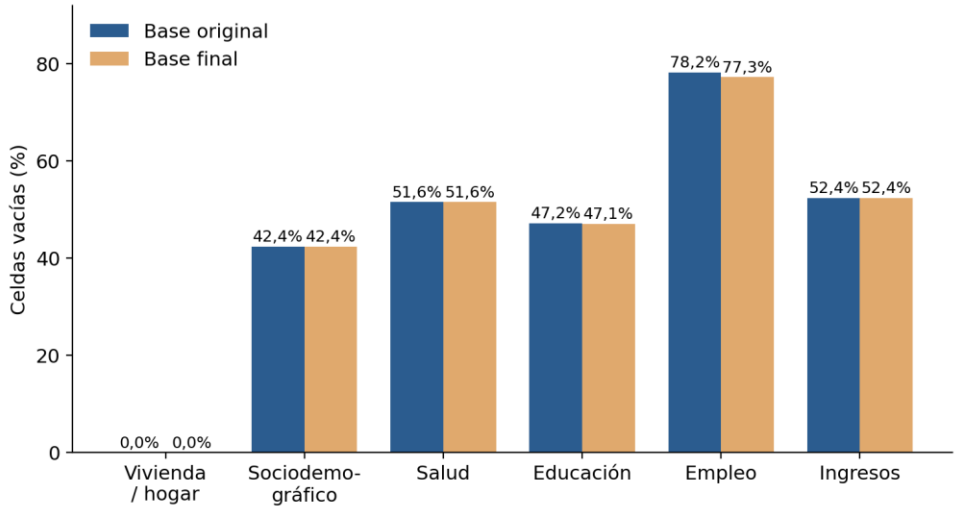
Columnas y vacíos por bloque temático: base original y base final

Bloque	Columnas	Vacíos originales	%	Vacíos finales	%	Ejemplos
Vivienda / hogar	18	180	0,0	80	0,0	*folio, totper, yhogpc, p0*
Sociodemográfico	27	452.304	42,4	452.304	42,4	*s01a_02, s01a_03, s01a_05*
Salud	44	896.083	51,6	896.083	51,6	*s02a_01a, s02b_06, cobersalud*
Educación	34	634.025	47,2	631.882	47,1	*s03a_01, niv_ed, aestudio*
Empleo	111	3.429.948	78,2	3.387.142	77,3	*s04b_12, condact, tothrs, ylab*
Ingresos	41	848.869	52,4	848.869	52,4	*s05a_01e, ynolab, yper*
Total	**275**	**6.261.409**	**57,6**	**6.216.360**	**53,5**	

Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024). Los porcentajes se calculan sobre las celdas del bloque original (sin las 19 columnas añadidas). El bloque Empleo incluye *ylab*; Ingresos incluye *ynolab* y *yper*.

Figura 1

Porcentaje de celdas vacías por bloque en la base original y en la base final



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024). Solo cambian Vivienda, Educación y Empleo; el resto de los vacíos se conservó.

4.2 Herramientas

Todo el procesamiento se hizo en R. Se usaron los paquetes *readr* para leer y escribir archivos, *dplyr* y *tidyr* para manipular tablas, *ggplot2* para las figuras, *stringr* para texto, *Hmisc* para etiquetar variables y *mice* para la imputación. Los informes se escribieron en Markdown, el código se versionó con Git y se publicó en GitHub. El archivo *01_config/packages.R* verifica e instala los paquetes que falten.

4.3 Arquitectura del proyecto

El repositorio se organiza en carpetas numeradas que reflejan el orden de trabajo (Tabla 8). La numeración de los scripts (00 a 32) es la misma de las carpetas, los informes, las figuras y los pasos de la bitácora, de modo que el script 24 tiene su informe *24_emp_imputacion_mice.md*, su figura *24_emp_imputacion_ylab.png* y su paso 24 en la bitácora.

Tabla 8

Estructura de carpetas del proyecto

Carpeta o archivo	Contenido	Para qué sirve
01_config	*packages.R*	Instala y verifica dependencias
02_R_helpers	*funciones.R*	Raíz del proyecto, bitácora, checkpoints y figuras
03_data/01_raw	*persona.csv* y *Diccionario de Persona.docx*	Insumos originales, sin tocar

Carpeta o archivo	Contenido	Para qué sirve
03_data/02_interim	*persona_00.rds* a *persona_30.rds*	31 checkpoints, uno por script (no se versionan)
03_data/03_processed	*persona_limpio.rds*, *persona_limpio.csv*, *persona_limpio_codificado.csv*	Productos finales
03_data/04_metadatos	*diccionario_corregido.csv*, *diccionario_final.csv*, *reglas_saltos.csv*	Metadatos del proceso
04_bitacora	*bitacora_limpieza.csv*	Registro de operaciones
05_scripts	Siete subcarpetas: setup y bloques 0 a 5	33 scripts de limpieza y un script de instalación
06_images	17 imágenes PNG	Evidencia gráfica
07_informes	33 informes técnicos, 6 resúmenes y un índice JSON	Documentación de cada paso
08_docs	Vacía en esta entrega	Reservada para documentación
run_all.R	Orquestador	Ejecuta los scripts en orden (con rutas por corregir, sección 5.7)

Nota. Elaboración propia con base en el contenido del repositorio *Dat253_Proyecto1*.

4.4 El ciclo de cada script

Cada script sigue el mismo ciclo, lo que facilita auditarlo. Primero fija la raíz del proyecto y carga las funciones comunes. Luego lee el checkpoint del script anterior (*persona_NN-1.rds*), aplica una transformación acotada, genera una figura si corresponde, guarda su propio checkpoint (*persona_NN.rds*) y registra una fila en la bitácora con la acción, la justificación y el número de filas afectadas. Los scripts de validación (11, 16, 21, 27 y 32) usan aserciones (*stopifnot*): si una condición no se cumple, el proceso se detiene en ese punto. Es el principio de *fail-fast*, "fallar rápido", para que un error no se propague a los bloques siguientes.

La bitácora tiene 12 columnas (Tabla 9). Contiene 38 filas para los 33 pasos porque los pasos 0, 1 y 12 se registraron más de una vez al volver a ejecutarse, y el paso 31 se repitió en la última ejecución, que se hizo después de la certificación del paso 32.

Tabla 9
Las doce columnas de la bitácora de limpieza

Columna	Qué registra
id_paso	Número del script (0 a 32)
fecha_hora	Marca de tiempo de la ejecución
responsable	Persona que ejecutó el paso
dataset	Base sobre la que se trabajó (*persona.csv*)
atributo	Variables afectadas
tipo_problema	Clase de problema detectado

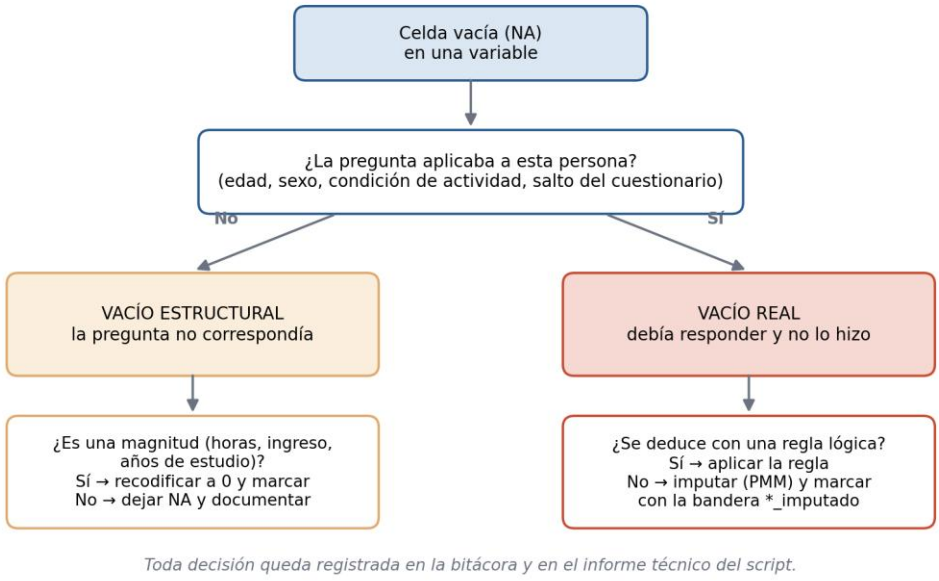
Columna	Qué registra
metodologia_fase	Fase del esquema de cinco fases
accion_realizada	Qué se hizo, con cifras
criterio_justificacion	Por qué se hizo
filas_afectadas	Número de filas modificadas
impacto_dataset	Dimensiones o efecto sobre la base
codigo_script	Ruta del script que lo produjo

Nota. Elaboración propia con base en *02_R_helpers/funciones.R* y *04_bitacora/bitacora_limpieza.csv*.

4.5 El árbol de decisión de la limpieza

La lógica general del trabajo se resume en Figura 2. Frente a cada celda vacía se pregunta primero si la pregunta aplicaba a la persona. Si no aplicaba, el vacío es estructural: si la variable es una magnitud (horas, ingreso, años de estudio) se recodifica a cero y, en cualquier caso, se documenta. Si aplicaba, el vacío es real: se intenta resolverlo con una regla lógica y, cuando no existe, se imputa y se marca con una bandera. Como se verá, la calidad de la limpieza depende casi por completo de la primera pregunta.

Figura 2
Árbol de decisión aplicado a cada variable con celdas vacías



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

4.6 Convención de nombres de variables

Las variables de la base cruda siguen el patrón *sSSp_NN*: *s* de sección, dos dígitos de sección, una letra de parte y el número de pregunta (por ejemplo, *s04b_12*, sección 4, parte B, pregunta

12). Las columnas derivadas por el INE no siguen ese patrón (*totper*, *yhog*, *ylab*, *p0*). Las columnas añadidas por el proyecto llevan sufijos que indican su función: *_imputado* para las banderas de linaje y el prefijo *tipo_na_* para las clasificaciones de vacío.

4.7 Antecedente: la primera versión del Bloque 0

Antes de la versión final, el repositorio tuvo una primera versión del Bloque 0 con ocho scripts, cuyos restos siguen en las carpetas *scripts*, *informes*, *data* y *docs*. Esa versión tomó un camino distinto: en lugar de escribir las reglas de salto a mano, las dedujo de los datos. Para cada variable con vacíos buscó, con un algoritmo voraz, hasta tres condiciones (rangos de edad o respuestas previas del cuestionario) que explicaran todas sus respuestas, con una tolerancia de 2% y grupos de al menos 50 filas. Así obtuvo reglas para 229 variables y clasificó los 6.261.409 vacíos en 6.167.672 estructurales (98,5%) y 93.737 reales. En el caso del ingreso laboral encontró que solo 148 de los 22.788 vacíos eran reales, no 2.770, porque casi todos coincidían con dos categorías ocupacionales de *s04b_12*.

La versión final reemplazó esa deducción por nueve reglas escritas a mano (script 05) y por la clasificación de cuatro variables (script 06). El repositorio no documenta el motivo del cambio. Como se muestra en la Tabla 10, la versión final cubre mucho más terreno (los seis bloques y la base completa), pero pierde precisión justamente donde la primera era más cuidadosa. Esta comparación vuelve en la discusión.

Tabla 10
Comparación entre la primera versión del Bloque 0 y la versión final

Aspecto	Primera versión (Bloque 0)	Versión final (bloques 0 a 5)
Reglas de salto	Deducidas de los datos para 229 variables	Nueve reglas escritas a mano
Variables clasificadas	Todas las que tienen vacíos	Cuatro: *s02b_06*, *aestudio*, *tothrs* y *ylab*
Vacíos reales estimados	93.737 en total	2.490 (todos en *ylab*)
Ingreso laboral real faltante	148 casos	2.490 casos
Cobertura	Solo el Bloque 0	Bloques 0 a 5, con variables derivadas
Producto	*persona_07* con máscara y versión codificada	*persona_limpio* (39.497 × 294)

Nota. Elaboración propia con base en *docs/ESTADO_PROYECTO.md*, *informes/05_reglas_de_salto.md*, *informes/06_clasificar_NA.md* y la bitácora.

5. Desarrollo: el recorrido

Cada sección sigue el mismo guion: qué nos preguntamos, con qué columnas trabajamos, qué técnica usamos, qué encontramos y cuánto quedó. Las cifras provienen de comparar la base original con la final y de la bitácora. Cuando un informe del repositorio da una cifra distinta, se indica en la sección 5.7.

5.1 Bloque 0 · Global (scripts 00 a 07)

Qué nos preguntamos. Antes de tocar un dato: ¿qué tan sucia está la base y podemos confiar en su diccionario? **Con qué columnas trabajamos.** Con las 275, sin distinción de tema. **Qué técnicas usamos.** La Tabla 11 resume los ocho scripts del bloque.

Tabla 11
Scripts del Bloque 0 (global)

Script	Técnica	Propósito	Filas afect.
00 auditoría inicial	Perfilado: vacíos por columna, tramos de vacío	Medir el estado de la base	0
01 diccionario corregido	Contraste de valores con el significado declarado	Crear *sexo*, *edad* y *parentesco*	39.497
02 tipos, unarias y etiquetas	Coerción de tipos; columnas de un solo valor; etiquetas	Identificadores como texto	39.497
03 normalizar texto	Quitar tildes y espacios; mayúsculas; vacío a NA	Homogeneizar 14 columnas abiertas	37
04 duplicados e integridad	Llave compuesta; conteo de jefes por hogar	Unicidad e integridad de hogares	0
05 reglas de salto	Reglas escritas a mano (nueve universos)	Definir quién debía responder	39.497
06 clasificar NA	Cruce de cada vacío con su universo	Separar estructurales de reales	39.497
07 recodificar estructurales	Máscara lógica; ceros analíticos	Recodificar a 0 y crear banderas	20.298

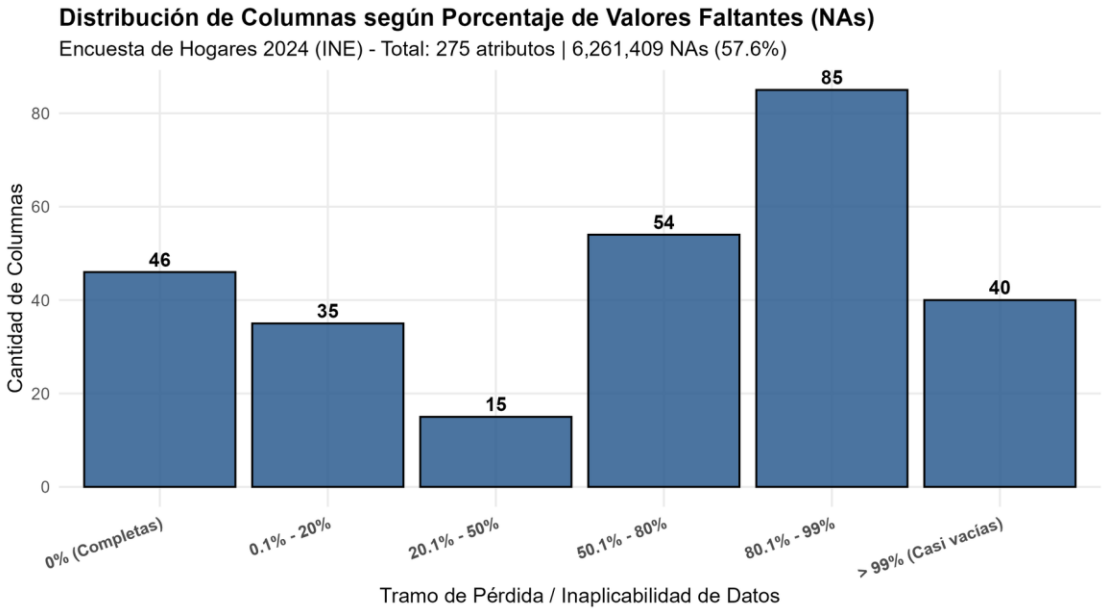
Nota. Elaboración propia con base en la bitácora de limpieza. "Filas afect." es el valor registrado en la bitácora, que en los scripts de diagnóstico cuenta las filas recorridas y no las modificadas.

5.1.1 La auditoría inicial (script 00)

El perfilado midió el porcentaje de vacíos de cada columna. Solo 46 de las 275 columnas están completas; 35 tienen hasta 20% de vacíos, 15 entre 20% y 50%, 54 entre 50% y 80%, 85 entre 80% y 99%, y 40 superan 99% (Figura 3). Es decir, 125 columnas están vacías en más de 80% de sus filas, lo que ya sugiere que no son columnas defectuosas sino preguntas dirigidas a una parte de la población.

Figura 3

Distribución de columnas según el porcentaje de valores faltantes



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

5.1.2 El diccionario corregido (script 01)

El diccionario describe *s01a_02* como parentesco, *s01a_03* como sexo y *s01a_05* como edad. Los valores dicen otra cosa: *s01a_02* contiene códigos 1 y 2 (sexo), *s01a_03* va de 0 a 98 (edad) y *s01a_05* de 1 a 14 (parentesco). La primera persona de la base, por ejemplo, tiene *s01a_02* = 1, *s01a_03* = 71 y *s01a_05* = 1: un hombre de 71 años que es jefe de hogar, y no una persona de "parentesco 1, sexo 71". El script creó tres columnas con nombres explícitos (*sexo*, *edad*, *parentesco*) y exportó *diccionario_corregido.csv* con la descripción y el bloque de cada columna (Tabla 12). La bitácora indica que la corrección se contrastó con el catálogo DDI del INE; ese catálogo no está en el repositorio, por lo que la verificación independiente queda pendiente (Apéndice E).

Tabla 12

Correcciones al diccionario de datos

Columna	El diccionario dice	Los datos muestran	Acción
s01a_02	Parentesco con el jefe	Códigos 1 y 2: sexo	Se crea *sexo*
s01a_03	Sexo	Valores de 0 a 98: edad	Se crea *edad*
s01a_05	Edad	Códigos de 1 a 14: parentesco	Se crea *parentesco*
totper	Total de personas del hogar	1 en 39.477 filas y vacío en 20	Se reconstruye (script 09)
condact	Códigos 1 a 3	Códigos 1 a 5 y 4.131 vacíos	Se usa solo 1 (ocupado) y 2 (desocupado)

Nota. Elaboración propia con base en *Diccionario de Persona.docx*, *persona.csv* y *diccionario_corregido.csv*.

5.1.3 Tipos, texto e integridad (scripts 02 a 04)

El script 02 convirtió *folio*, *upm* y *estrato* a texto, porque son identificadores y sumarlos o promediarlos no tiene sentido, y *depto*, *area* y *nro* a entero. Detectó además las columnas con un solo valor (*totper*, *s02a_01e* y *s05c_09e*) y asignó etiquetas descriptivas a 16 variables clave. El script 03 normalizó 14 columnas de texto libre (quitar espacios dobles, pasar a mayúsculas, eliminar tildes y la letra ñ, convertir cadenas vacías en vacío); solo 37 celdas cambiaron, lo que muestra que el texto de partida ya era razonablemente limpio. El script 04 verificó que no hay filas duplicadas ni repeticiones de la llave (*folio*, *nro*), que cada uno de los 12.718 hogares tiene exactamente una persona con parentesco 1 (jefe o jefa) y que la numeración *nro* es correlativa en todos los hogares. Si cualquiera de estas condiciones hubiera fallado, el script se habría detenido.

5.1.4 Reglas de salto (script 05)

Este es el paso conceptual más importante del bloque. El script formalizó nueve universos, es decir, nueve condiciones que determinan a quién se le hace cada grupo de preguntas (Tabla 13). Cada regla se guardó en *reglas_saltos.csv* con su filtro en código R, el tamaño del universo y la cantidad de vacíos esperados por inaplicabilidad.

Tabla 13

Las nueve reglas de salto del cuestionario y el tamaño de cada universo

N.º	Sección y tema	Filtro	Universo	Inaplicables
1	S1 Demografía general	Toda la población	39.497	0
2	S2-B Fecundidad	Mujer de 13 a 50 años	11.328	28.169
3	S2-C Desarrollo infantil	Edad de 0 a 5 años	3.434	36.063
4	S2-D Bono Juana Azurduy	Edad de 0 a 2 años	1.529	37.968
5	S3-A/B Educación	Edad de 4 años o más	37.354	2.143
6	S3-C Tecnologías (TIC)	Edad de 5 años o más	36.716	2.781
7	S4-A Empleo (PET)	Edad de 14 años o más	29.953	9.544
8	S4-B a F Ocupados e ingresos	Condición de actividad = 1	19.479	20.018
9	S5-A Renta Dignidad	Edad de 60 años o más	5.166	34.331

Nota. Elaboración propia con base en *reglas_saltos.csv*. Universos recalculados con la base final.

Las reglas de las secciones 2 a 5 coinciden exactamente con la cantidad de vacíos observada en las variables de control: *s02b_06* (embarazo) tiene 28.169 vacíos, justo los hombres y las mujeres fuera de 13 a 50 años; *aestudio* tiene 2.143 vacíos, las personas menores de 4 años; *tothrs* tiene 20.018, las personas que no son ocupadas; y *s05a_01e* tiene 34.331, las menores de 60 años.

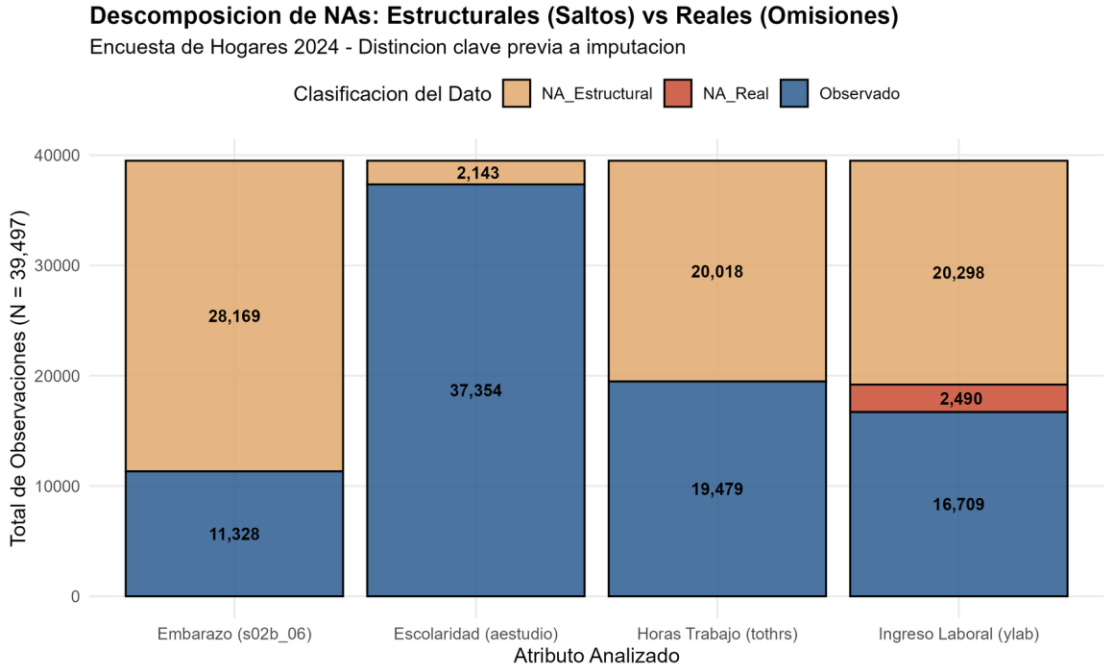
Esa coincidencia exacta es la mejor evidencia de que las reglas están bien escritas para esas variables.

5.1.5 Clasificación y recodificación de vacíos (scripts 06 y 07)

El script 06 creó cuatro columnas *tipo_na_* que etiquetan cada celda como *Observado*, *NA_Estructural* o *NA_Real* para *s02b_06*, *aestudio*, *tothrs* y *ylab* (Figura 4). El resultado es nítido: en embarazo, escolaridad y horas no hay ni un solo vacío real. Todo el problema de datos perdidos se concentra en el ingreso laboral, donde la clasificación arroja 20.298 vacíos estructurales y 2.490 reales.

Figura 4

Descomposición de los vacíos en estructurales y reales para las cuatro variables clasificadas



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

El script 07 recodificó a cero los vacíos estructurales de las tres variables que son magnitudes y creó las banderas *aestudio_imputado*, *tothrs_imputado* y *ylab_imputado*, inicializadas en 0. En total fueron 42.459 celdas: 20.298 de ingreso laboral, 20.018 de horas trabajadas y 2.143 de años de estudio. Es una recodificación y no una imputación: a un inactivo se le asigna 0 horas y 0 Bs porque eso es lo que trabajó y ganó, y a un menor de 4 años se le asignan 0 años de estudio porque no ha cursado ninguno. La Tabla 14 resume el efecto del bloque.

Tabla 14
Resultado del Bloque 0

Indicador	Antes	Después	Efecto
Columnas	275	285	+3 demográficas, +4 *tipo_na_*, +3 banderas
Vacíos en *ylab*	22.788	2.490	20.298 recodificados a 0 Bs
Vacíos en *tothrs*	20.018	0	Recodificados a 0 horas
Vacíos en *aestudio*	2.143	0	Recodificados a 0 años
Duplicados	0	0	Llave (*folio*, *nro*) íntegra
Hogares con un solo jefe	12.718	12.718	Sin excepciones

Nota. Elaboración propia con base en la bitácora (pasos 0 a 7) y comparaciones directas con la base original.

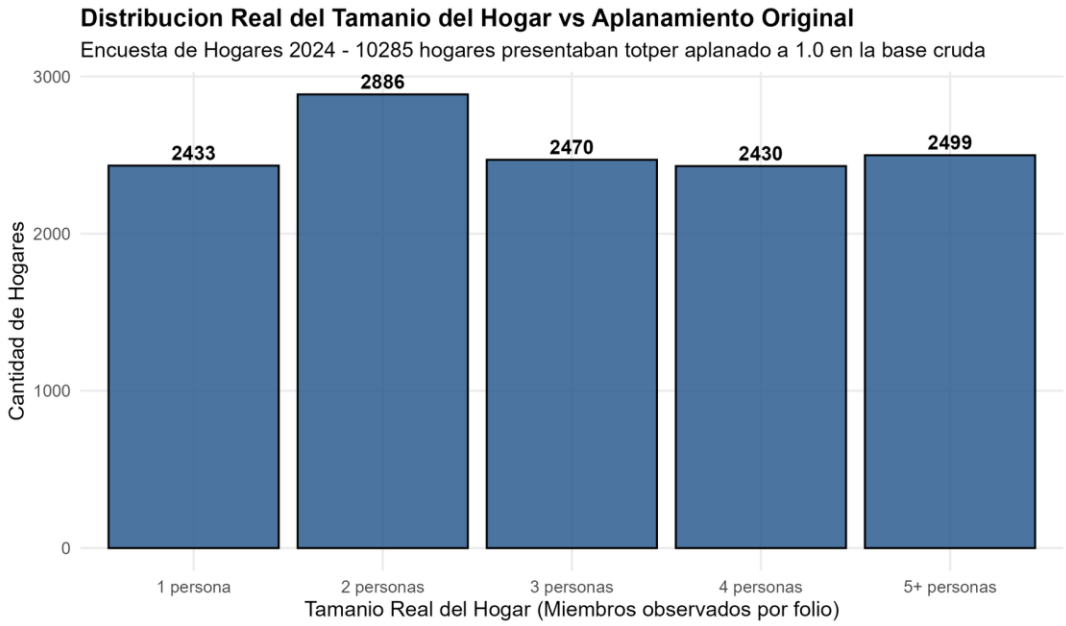
5.2 Bloque 1 · Vivienda y hogar (scripts 08 a 11)

Qué nos preguntamos. ¿Por qué el tamaño del hogar vale 1 casi siempre? **Con qué columnas trabajamos.** Con *totper*, *tipohogar*, *yhog*, *yhogpc*, *z*, *zext*, *p0* y *pext0*. **Qué técnicas usamos.** Agregación por hogar con *group_by*, comparación contra fórmulas y verificación de reglas lógicas.

El script 08 contó los miembros reales de cada *folio* y los comparó con *totper*: en 10.285 de los 12.718 hogares el tamaño real era distinto del declarado, porque *totper* valía 1 en 39.477 filas. Cabe destacar que solo los 2.433 hogares unipersonales coincidían, y por casualidad. El script 09 reconstruyó la columna contando las filas de cada hogar, lo que modificó 37.064 filas (37.044 por valor distinto y 20 por estar vacío). El tamaño de hogar quedó entre 1 y 15 personas, con promedio de 3,11 miembros por hogar (Figura 5).

Figura 5

Distribución real del tamaño del hogar frente al aplanamiento original

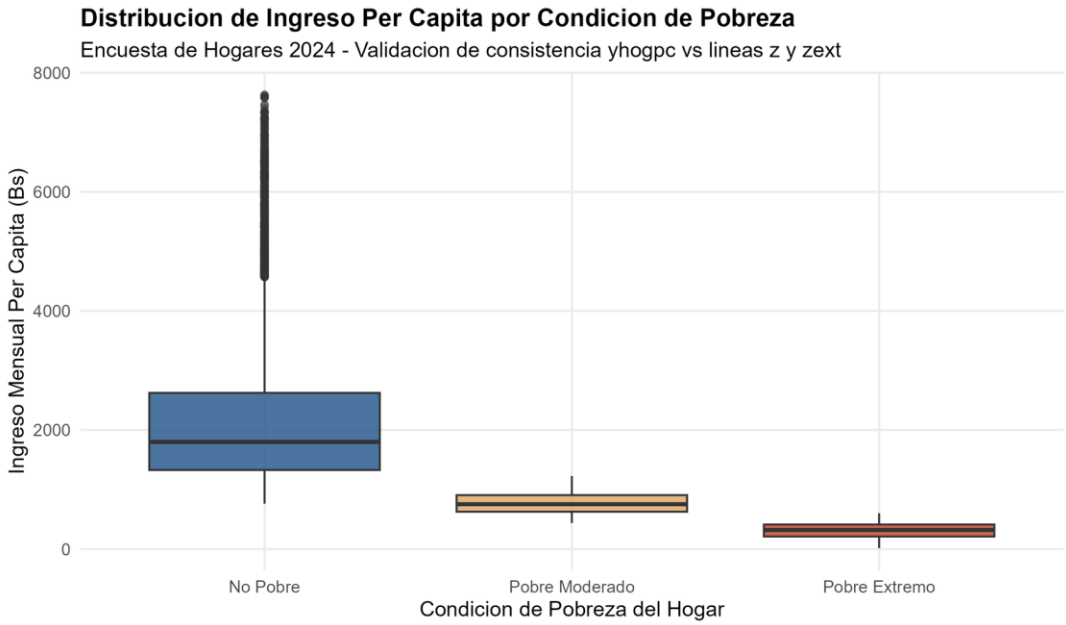


Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

El script 10 revisó el ingreso per cápita. En la base original *yhogpc* ya concordaba con el ingreso del hogar dividido entre el número real de miembros en 99,8% de las filas, de modo que el error estaba en *totper* y no en *yhogpc*; el script modificó solo 45 filas con diferencias mayores a 0,05 Bs. También verificó que ninguna línea de pobreza extrema supere a la de pobreza moderada ($zext \leq z$) y que todo pobre extremo sea pobre moderado (*pext0* = 1 implica *p0* = 1), condiciones que la base ya cumplía. El script 11 cerró el bloque con cinco aserciones (Tabla 15).

Figura 6

Ingreso per cápita del hogar según condición de pobreza



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024). La separación entre grupos confirma que *p0* y *pext0* son coherentes con *yhogpc*.

Tabla 15

Identidades y reglas verificadas en el Bloque 1

Verificación	Expresión	Resultado
Tamaño del hogar completo y positivo	*totper* > 0 en todas las filas	Cumple (20 vacíos reconstruidos)
Hogares unipersonales	*tipohogar* = 1 implica *totper* = 1	Cumple
Jefatura única	Un solo *parentesco* = 1 por *folio*	Cumple en 12.718 hogares
Líneas de pobreza	*zext* ≤ *z*	Cumple
Inclusión de conjuntos	*pext0* = 1 implica *p0* = 1	Cumple

Nota. Elaboración propia con base en los scripts 10 y 11.

5.3 Bloque 2 · Salud (scripts 12 a 16)

Qué nos preguntamos. ¿Hay datos de salud perdidos o solo preguntas que no correspondían? **Con qué columnas trabajamos.** Con 44 columnas de la sección 2, en particular *cobersalud*, las dificultades permanentes (*s02a_04a* a *s02a_04f*), los gastos (*s02a_03a* a *s02a_03e*) y las preguntas de fecundidad (*s02b_*). **Qué técnicas usamos.** Diagnóstico de universos, filtros biológicos, imputación condicional prevista y agregación de gastos.

Tabla 16

Preguntas de salud, universo y resultado del diagnóstico

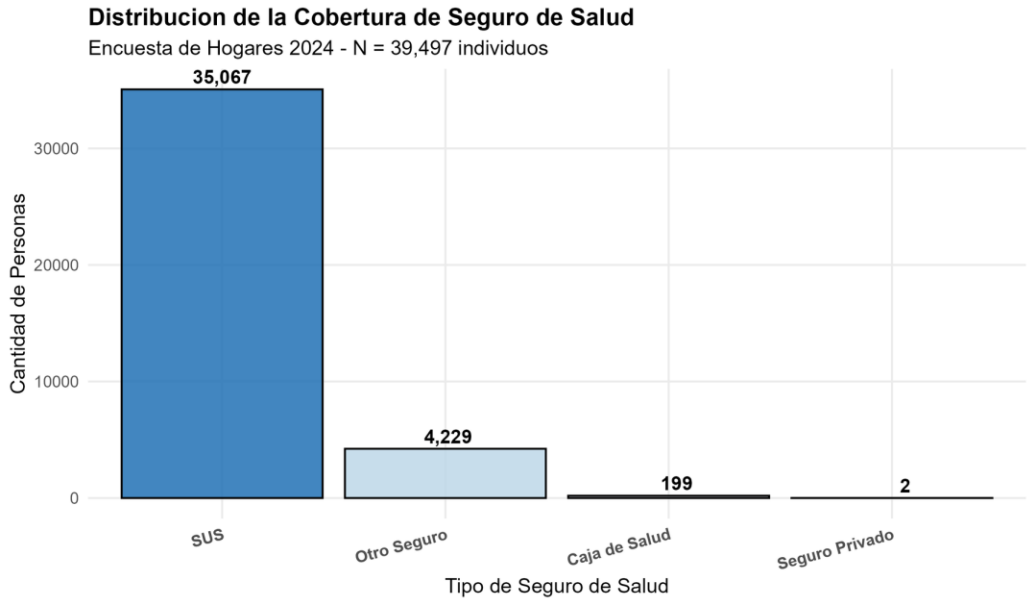
Pregunta	Universo	Vacíos originales	Resultado
Cobertura de seguro (*cobersalud*)	Toda la población	0	Sin vacíos; no se imputó nada
Dificultades permanentes (*s02a_04a-f*)	Toda la población	0	Dominio 1 a 4 verificado
Gastos de bolsillo (*s02a_03a-e*)	Toda la población	0	Se verificó no negatividad
Embarazo (*s02b_06*)	Mujeres de 13 a 50 años (11.328)	28.169	Todos estructurales
Último parto y atención (*hnv_ult_a*)	Mujeres de 13 a 50 años	28.169	Sin respuestas fuera del universo

Nota. Elaboración propia con base en *persona.csv* y en los informes 12 a 16.

El hallazgo es que las variables de salud de la sección 2-A no tienen vacíos que tratar, de modo que el script 13 no modificó ninguna celda y la bandera *cobersalud_imputado* quedó en 0 para todas las personas. El script 14 comprobó que ninguna respuesta de fecundidad exista fuera del universo de mujeres de 13 a 50 años (0 anomalías). Una observación metodológica: el script asume que *cobersalud* tiene cinco categorías, con 5 = "sin seguro", pero en los datos solo aparecen los códigos 1 (35.067 personas), 2 (199), 3 (2) y 4 (4.229). Las etiquetas del gráfico de cobertura (Figura 7) provienen de esa suposición y deben confirmarse con la boleta; en particular, el código 4 podría corresponder a "ninguno" y no a "otro seguro" (Apéndice E).

Figura 7

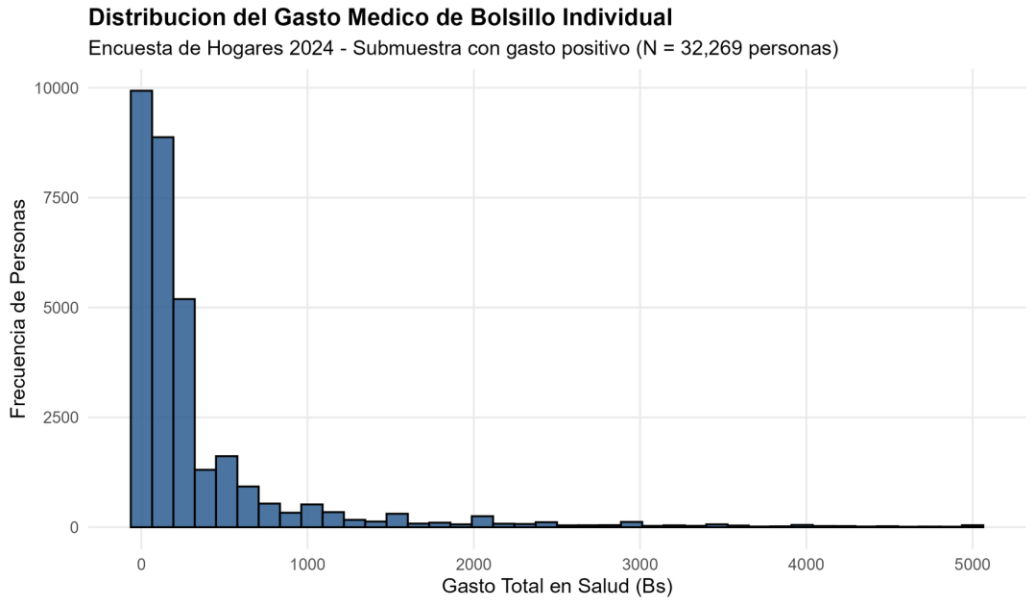
Distribución de la cobertura de seguro de salud según los códigos de la base



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024). Las etiquetas de los códigos 2 a 4 son una suposición del script y están por confirmar.

El script 15 revisó los cinco rubros de gasto y creó *gasto_salud_total* como su suma. Hay 32.269 personas con gasto positivo, con una mediana de 120 Bs entre quienes gastan; el rubro más frecuente es medicinas (31.930 personas) y el de mayor monto medio, internación (5.227 Bs entre quienes lo declaran). La distribución es muy asimétrica (Figura 8). El script 16 cerró el bloque con aserciones sobre cobertura, dificultades, universo de fecundidad y gasto.

Figura 8
Gasto de bolsillo en salud entre quienes declaran gasto



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

5.4 Bloque 3 · Educación (scripts 17 a 21)

Qué nos preguntamos. ¿Los vacíos de escolaridad son faltantes o son niños pequeños? **Con qué columnas trabajamos.** Con 34 columnas de la sección 3, en particular *aestudio*, *niv_ed*, *niv_ed_g*, *s03a_01* (alfabetismo) y las preguntas de tecnologías de la información (*s03c_*). **Qué técnicas usamos.** Perfilado por grupo de edad, regla de consistencia biológica y construcción de dos variables derivadas.

Tabla 17
Preguntas de educación y su universo

Pregunta	Universo	Vacíos	Tratamiento
Años de estudio (*aestudio*)	Edad de 4 años o más (37.354)	2.143	Todos estructurales, recodificados a 0 en el script 07
Alfabetismo (*s03a_01*)	Edad de 4 años o más	2.143	Los mismos 2.143 menores de 4 años
Uso de internet (*s03c_14*)	Edad de 5 años o más (36.716)	Por regla	Se crea *uso_internet*

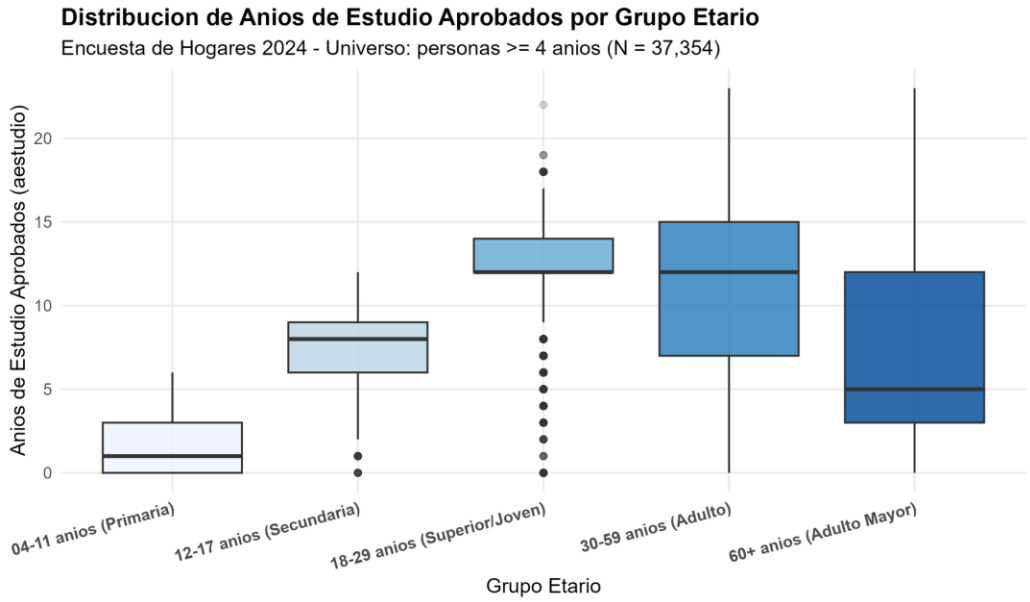
Nota. Elaboración propia con base en *persona.csv* y los informes 17 a 21.

Los 2.143 vacíos de *aestudio* corresponden exactamente a los 2.143 menores de 4 años, de modo que los scripts 17 y 18 no encontraron ningún vacío real: no hubo imputación por alfabetismo ni por la mediana de edad, a pesar de que el código está preparado para hacerlo, y

aestudio_imputado vale 0 en toda la base. El script 19 aplicó una cota biológica: nadie puede haber aprobado más años de estudio que su edad menos 4. Tres personas la excedían y se acotaron (Figura 10).

Figura 9

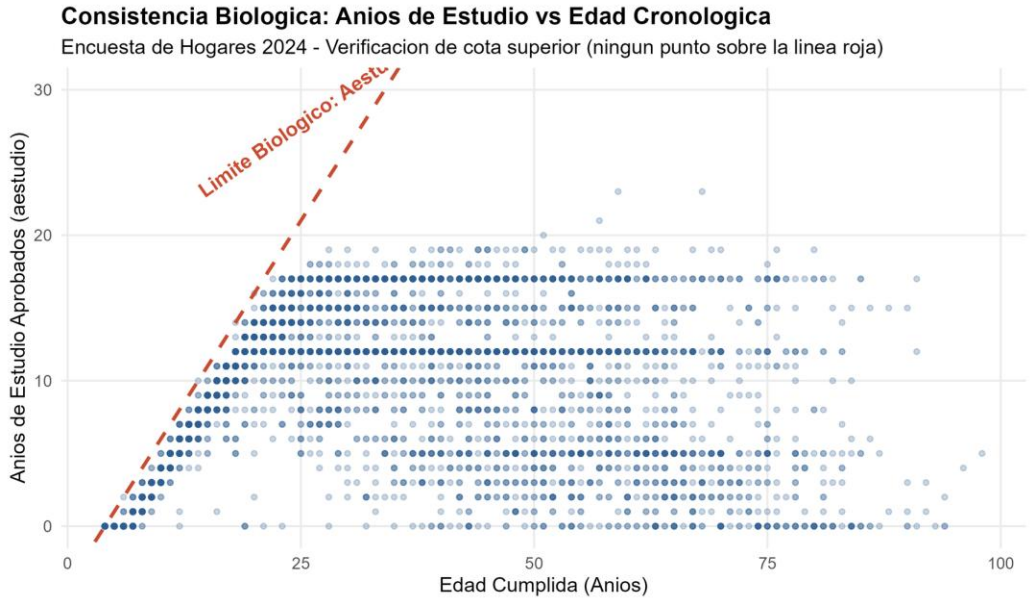
Años de estudio aprobados por grupo de edad en la población de 4 años o más



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

Figura 10

Años de estudio frente a edad con la cota biológica (edad menos 4)

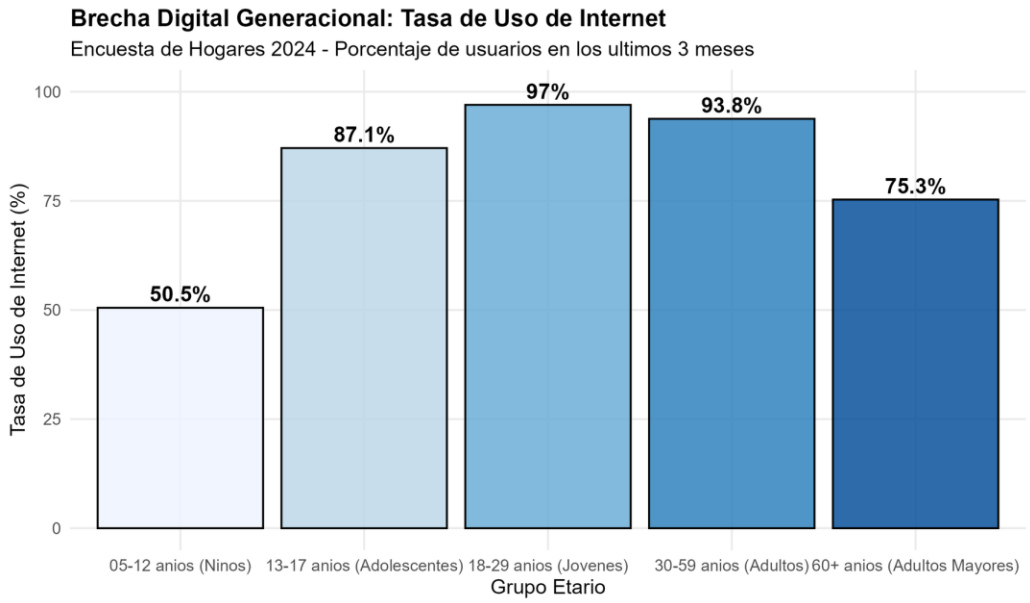


Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024). Ningún punto supera la línea de límite.

El script 20 creó dos variables. La primera, *uso_internet*, vale 1 para las 30.854 personas de 5 años o más que declararon usarlo, es decir, 84,0% de ese universo. La brecha entre grupos de edad es marcada (Figura 11): 64,8% entre 5 y 17 años, 97,0% entre 18 y 29, 93,8% entre 30 y 59 y 75,3% a partir de los 60. La segunda, *clima_educativo_hogar*, es el promedio de años de estudio de los adultos (18 años o más) del hogar, una medida habitual en estudios de capital humano; en los 20 hogares sin adultos toma los años de estudio de la propia persona. El script 21 verificó con cinco aserciones que *aestudio* esté completo, respete la cota, sea 0 en los menores de 4 años y no sea negativo. Hay un supuesto sin confirmar: el script toma *s03c_14* como la pregunta de uso de internet porque es la primera de una lista de candidatas (Apéndice E).

Figura 11

Tasa de uso de internet por grupo de edad



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

5.5 Bloque 4 · Empleo e ingresos laborales (scripts 22 a 27)

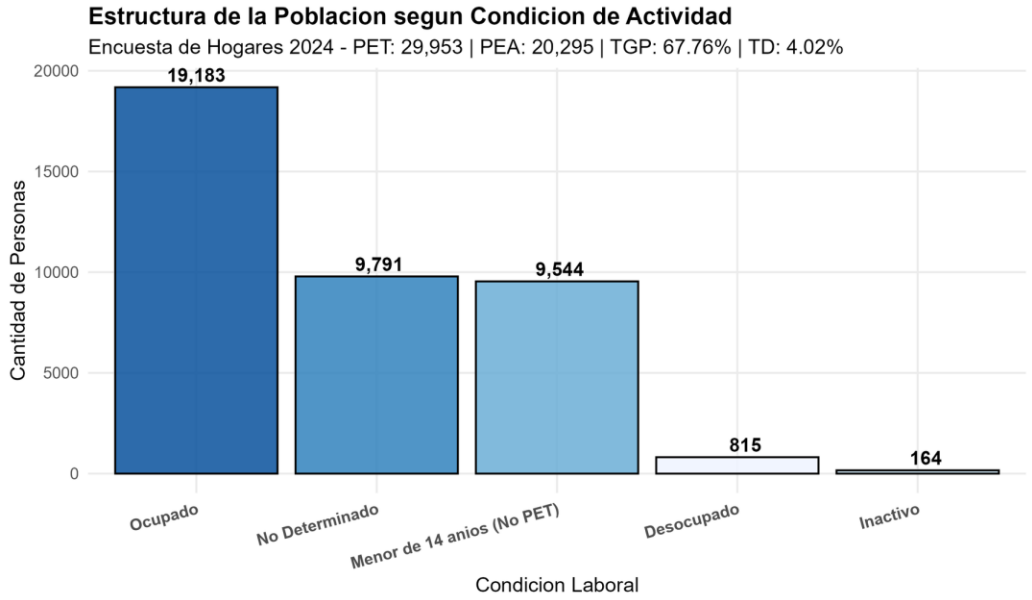
Qué nos preguntamos. ¿Cuántos ingresos laborales faltan realmente y cómo se completan? **Con qué columnas trabajamos.** Con 111 columnas de empleo, en especial *condact*, *pet*, *s04b_12*, *tothrs* y *ylab*. **Qué técnicas usamos.** Cálculo de tasas del mercado laboral, acotamiento por cota física, imputación con PMM y variables de calidad del empleo.

5.5.1 Diagnóstico del mercado laboral (script 22)

La población en edad de trabajar (PET, 14 años o más) suma 29.953 personas. Hay 19.479 ocupados y 816 desocupados, de modo que la población económicamente activa (PEA) sería de 20.295 personas y la tasa de desempleo abierto de 4,0%. La tasa global de participación calculada por el script (PEA entre PET) es 67,8% (Figura 12). Hay un detalle: entre los ocupados hay 296 niños de 7 a 13 años, que no pertenecen a la PET. Si se los excluye del numerador, la participación baja a 66,8% (19.998 sobre 29.953). Es una diferencia pequeña, pero ilustra por qué conviene verificar los universos.

Figura 12

Condición de actividad de la población



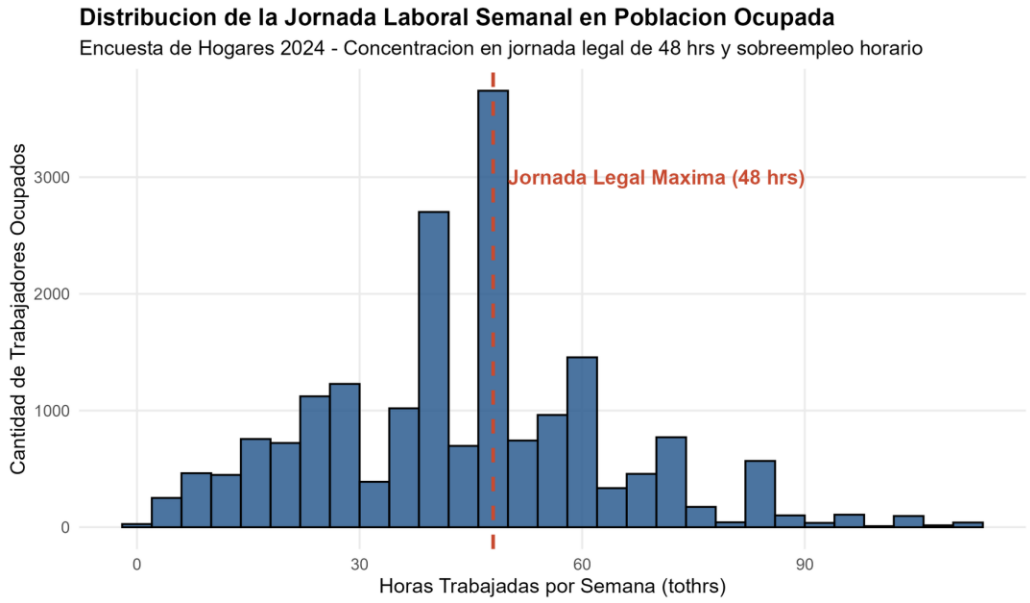
Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024). Los códigos 4 y 5 de *condact* no figuran en el diccionario.

5.5.2 Horas trabajadas (script 23)

Los ocupados con horas vacías son 0: las 20.018 celdas vacías de *tothrs* corresponden todas a no ocupados, ya recodificadas a 0. El script trató entonces solo los valores extremos: 29 jornadas superaban las 112 horas semanales (el máximo observado era 192) y se acotaron a 112. Entre los ocupados, la mediana de la jornada es 45 horas y la media 44,4, con una concentración visible en la jornada legal de 48 horas (Figura 13).

Figura 13

Horas trabajadas por semana entre los ocupados



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

5.5.3 Imputación del ingreso laboral con PMM (script 24)

Este es el paso que más modificó la base. El script 24 imputó los 2.490 ingresos laborales vacíos de ocupados con *mice* y el método PMM, con ocho columnas (*ylab*, *edad*, *sexo*, *area*, *depto*, *aestudio*, *tothrs* y *clima_educativo_hogar*), una imputación (m = 1), cinco iteraciones y semilla 253. Los valores quedaron entre 0 y 75.065 Bs, sin negativos, y el ingreso mediano de los imputados que reciben algo es 1.500 Bs frente a 2.706 Bs de los observados.

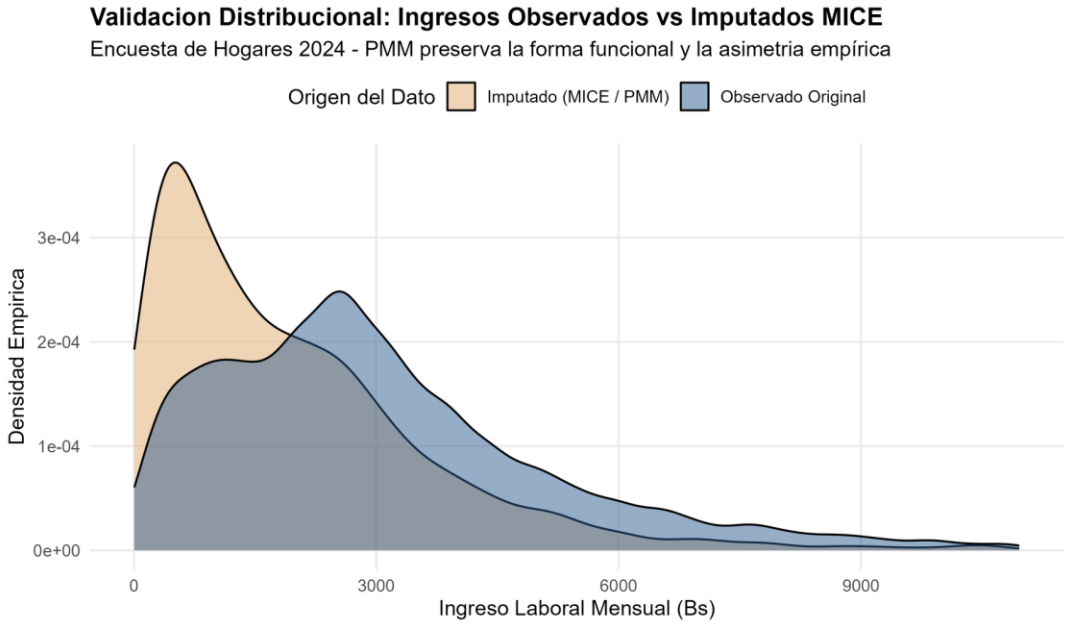
La Figura 14 muestra las dos distribuciones. Los informes del repositorio describen las curvas como "idénticas", pero en el gráfico los imputados forman un pico claro cerca de los 500 Bs, mientras que los observados lo tienen cerca de los 2.700 Bs. Dos hechos explican la diferencia y ambos se descubrieron al verificar la base:

1. **Los donantes incluyen ceros que no son ingresos.** El script 07 había recodificado a 0 el ingreso de 280 niños de 7 a 13 años que figuran como ocupados pero están fuera de la PET. El script 24 seleccionó a todos los ocupados (*condact* = 1) como universo del modelo, de manera que esos 280 ceros quedaron como donantes legítimos. El resultado es que 251 de las 2.490 imputaciones valen exactamente 0, cuando el ingreso observado mínimo es 6,67 Bs.

2. **Casi todos los imputados pertenecen a dos categorías que casi no declaran ingreso.** La Figura 15 muestra que, en la categoría 6 de *s04b_12*, 99,5% de los ocupados de la PET no tiene ingreso laboral, y en la 7, 97,7%. Allí se concentran 2.389 de las 2.490 imputaciones (95,9%). Si una categoría tiene casi 100% de vacíos, el vacío no es una omisión al azar sino una característica de esa ocupación, probablemente trabajo sin remuneración (por ejemplo, el trabajo familiar no pagado), hipótesis que debe confirmarse con la boleta. Para esas personas, el ingreso laboral podría no existir.

Figura 14

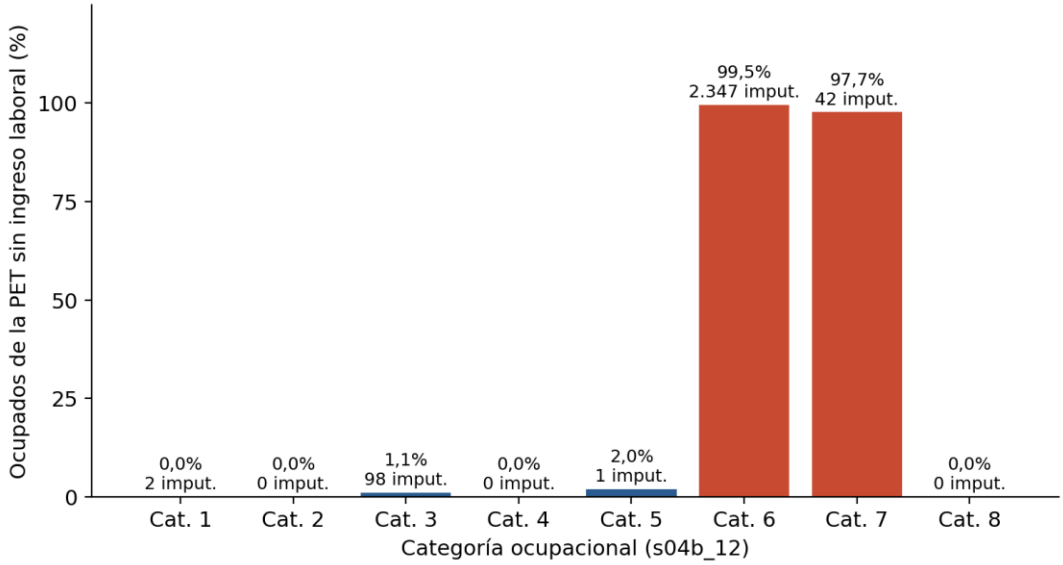
Ingreso laboral observado frente a imputado con PMM



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024). Los informes del repositorio califican las distribuciones de superpuestas; la figura muestra un desplazamiento hacia valores bajos.

Figura 15

Ocupados de la PET sin ingreso laboral por categoría ocupacional, e imputaciones recibidas



Nota. Elaboración propia con base en *persona.csv* y *persona_limpio.csv*. Las categorías 6 y 7 concentran 2.389 de las 2.490 imputaciones.

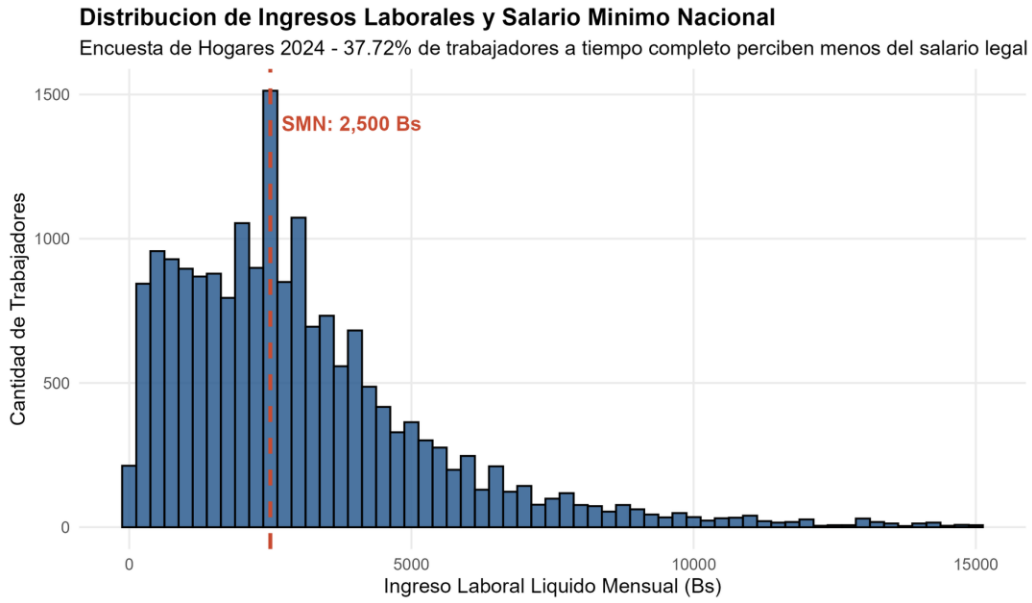
Esto no invalida el uso de PMM, que es una técnica adecuada cuando el dato existe y falta. Lo que ocurre es que el paso previo, la clasificación entre vacío estructural y vacío real, no se aplicó a esta variable con el mismo rigor que a las demás. La primera versión del Bloque 0 había señalado que solo 148 vacíos de *ylab* eran reales justamente por esta razón (sección 4.7).

5.5.4 Salario mínimo y variables sintéticas (scripts 25 y 26)

El script 25 creó *debajo_smn*, que vale 1 para el ocupado con jornada de 40 horas o más y un ingreso menor al Salario Mínimo Nacional de 2024 (Bs 2.500; Decreto Supremo 5154). Son 4.899 personas, 37,7% de los 12.989 ocupados a tiempo completo (Figura 16). Como el ingreso de 2.490 personas fue imputado, esta cifra depende de la imputación; entre los ocupados a tiempo completo con ingreso observado el porcentaje es 35,8%. El script 26 calculó *ingreso_horario* (ingreso mensual dividido entre las horas semanales por 4,33), con mediana de 13,5 Bs por hora, y dos banderas de jornada: *subempleo_horario* (menos de 40 horas, 6.490 personas) y *sobreempleo_horario* (más de 48 horas, 6.563 personas). El gráfico por nivel de instrucción muestra la relación creciente entre estudios e ingreso por hora (Figura 17). El script 27 cerró el bloque con seis aserciones sobre completitud, no negatividad, ceros en no ocupados, cota de 112 horas y dominio de las banderas.

Figura 16

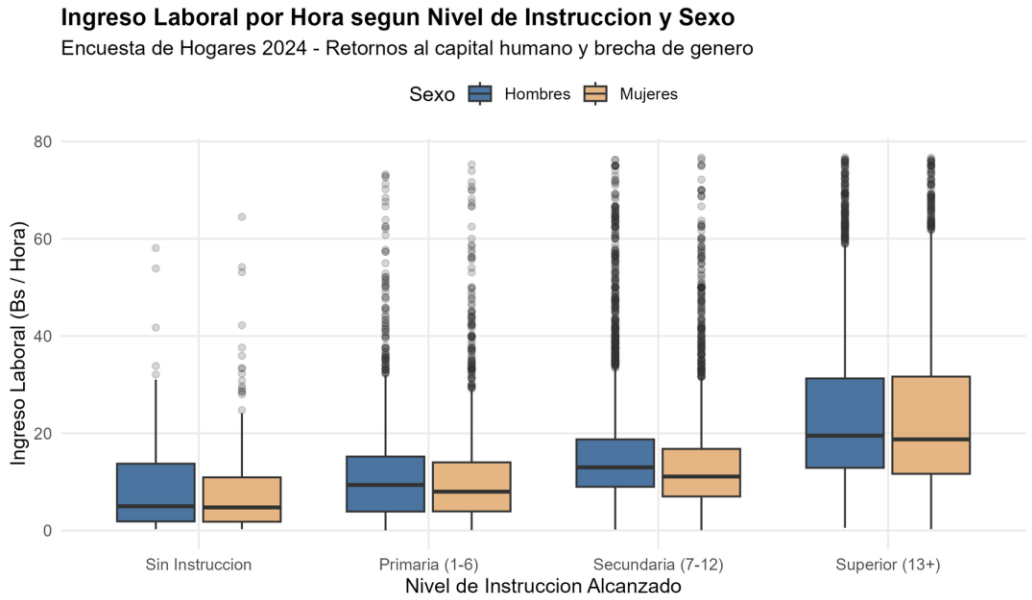
Ingreso laboral mensual y Salario Mínimo Nacional



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

Figura 17

Ingreso laboral por hora según nivel de instrucción y sexo



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

Tabla 18
Qué explica los vacíos de empleo e ingresos y cómo se trataron

Variable	Vacíos originales	Causa	Tratamiento
tothrs	20.018	No ocupados	Recodificado a 0; 29 valores acotados a 112
ylab estructural	20.298	No ocupados (incluye 280 niños ocupados fuera de la PET)	Recodificado a 0
ylab real	2.490	Ocupados de la PET sin ingreso declarado	Imputación PMM con bandera *ylab_imputado* (95,9% en categorías 6 y 7)

Nota. Elaboración propia con base en *persona.csv*, la bitácora y los scripts 07, 23 y 24.

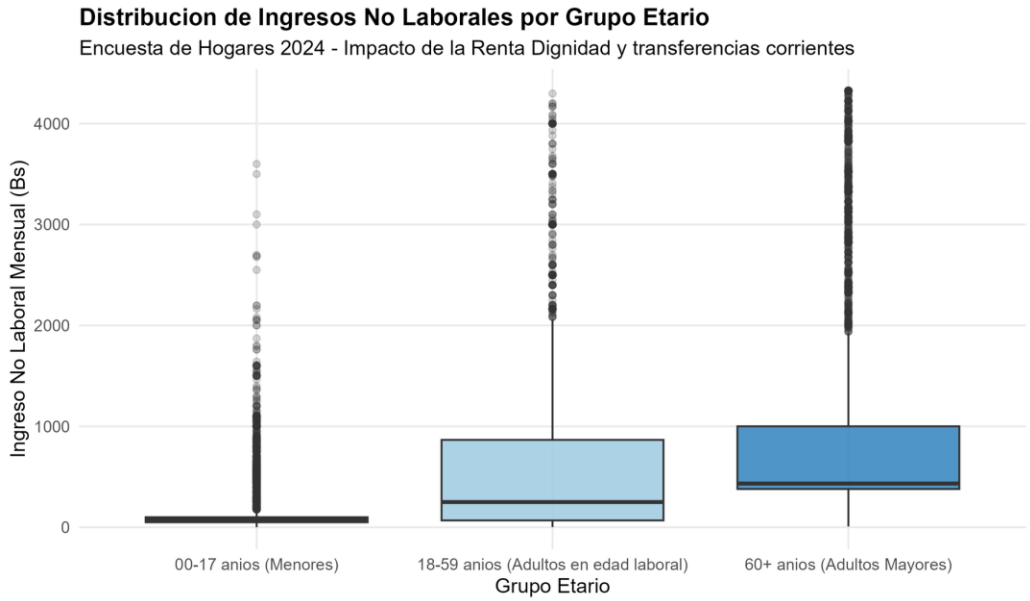
5.6 Bloque 5 · Ingresos no laborales y cierre (scripts 28 a 32)

Qué nos preguntamos. Con los ingresos laborales completados, ¿se cierran las cuentas del hogar? **Con qué columnas trabajamos.** Con *ynolab*, *s05a_*, *yper*, *yhog*, *yhogpc*, *z*, *zext*, *p0* y *pext0*. **Qué técnicas usamos.** Reglas normativas, identidades contables y exportación.

Los scripts 28 y 29 revisaron el ingreso no laboral, que no tiene vacíos en la base original: 17.863 personas reciben algún monto. Se comprobó que nadie menor de 60 años declara Renta Dignidad (0 anomalías) y que 4.852 de las 5.166 personas de 60 años o más (93,9%) declaran recibirla. El script 29 no modificó ninguna celda, y *ynolab_imputado* vale 0 para toda la base (Figura 18).

Figura 18

Ingresos no laborales por grupo de edad

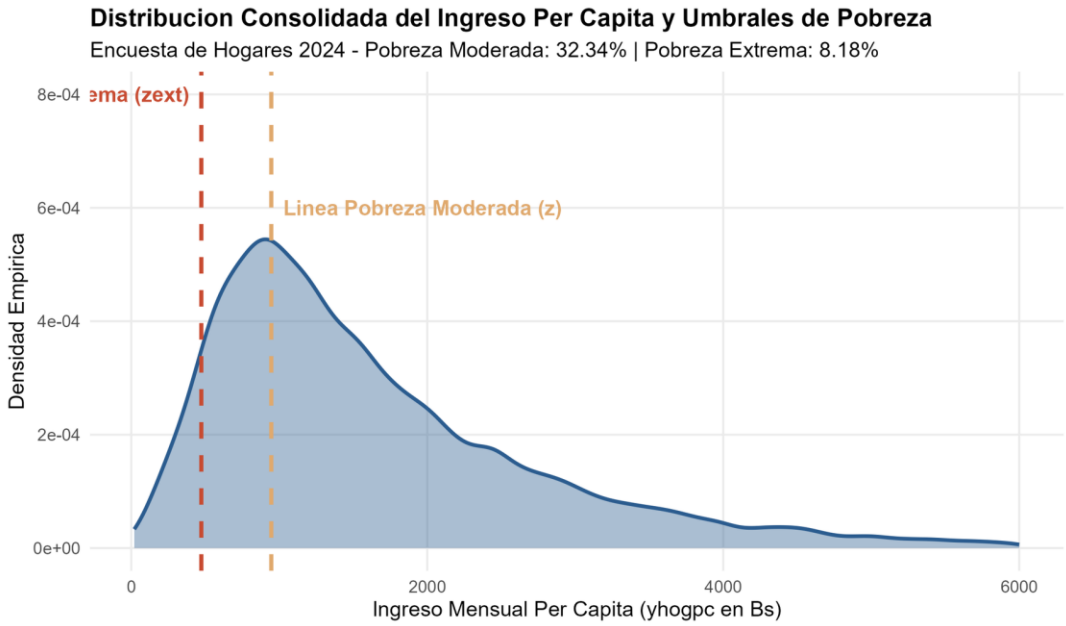


Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

El script 30 es el que cierra el circuito contable y donde la imputación se propaga. Recalculó el ingreso individual como *yper* = *ylab* + *ynolab*; el del hogar como la suma de los *yper* de sus miembros; el per cápita como *yhog* entre *totper*; y las condiciones de pobreza (*p0* si *yhogpc* < *z*, *pext0* si *yhogpc* < *zext*, con *p0* forzado a 1 cuando *pext0* = 1). Gracias a que el script 09 había reconstruido *totper*, las identidades se cumplen en el 100% de las filas. El efecto sobre la base es considerable (Tabla 19): 2.239 ingresos individuales cambiaron (los 2.490 imputados, menos los 251 que valen 0), 7.326 ingresos de hogar, 6.945 ingresos per cápita y 2.155 clasificaciones de pobreza moderada.

Figura 19

Ingreso per cápita del hogar y líneas de pobreza en la base final



Nota. Elaboración propia con base en la Encuesta de Hogares 2024 (INE, 2024).

Tabla 19

Variables cuyo valor cambió entre la base original y la base final

Variable	Filas modificadas	Origen del cambio
totper	37.044 (+20 vacíos)	Reconstrucción por conteo de filas (script 09)
yper	2.239	Ingresos laborales imputados (script 24)
yhog	7.326	Propagación de *yper* al hogar (script 30)
yhogpc	6.945	Propagación y nuevo *totper* (script 30)
p0	2.155	Nuevo ingreso per cápita frente a la línea *z*
pext0	1.465	Nuevo ingreso per cápita frente a la línea *zext*
tothrs	29	Acotamiento a 112 horas (script 23)
aestudio	3	Cota biológica (script 19)

Nota. Elaboración propia a partir de la comparación celda por celda entre *persona.csv* y *persona_limpio.csv*, con tolerancia de 0,01 Bs en las variables monetarias.

Los scripts 31 y 32 exportaron el producto final y lo certificaron. El 31 guardó *persona_limpio.rds*, *persona_limpio.csv* y *persona_limpio_codificado.csv* (las tres con 39.497 filas y 294 columnas) y *diccionario_final.csv*, con tipo, etiqueta, vacíos y valores distintos de cada columna. El 32 aplicó una batería de aserciones globales (14 llamadas a *stopifnot*, agrupadas en 10 controles en el informe) sobre dimensiones, llave, jefatura única, *totper*, cobertura, escolaridad, ingresos, horas, identidades contables y pobreza. El proceso pasó todas, lo cual significa que las

reglas que el proyecto se impuso se cumplen; no significa que las reglas sean suficientes, como muestra la sección siguiente.

5.7 Errores, discrepancias y correcciones del camino

Al contrastar los informes y resúmenes del repositorio con los datos aparecen diferencias que conviene corregir antes de entregar el material. Varias provienen de ejecuciones anteriores de los scripts: los textos conservan cifras de una versión previa. La Tabla 20 las reúne.

Tabla 20

Discrepancias encontradas entre la documentación y los datos

N.º	Documentación dice	Los datos muestran	Qué corregir
1	2.751 ingresos imputados y 52 horas imputadas (informes 22, 24 y resumen del Bloque 4)	2.490 ingresos y 0 horas	Actualizar los textos; la bitácora sí es correcta
2	Base final de 292 columnas (informe 31, resumen del Bloque 5)	294 columnas (275 + 19)	Corregir el número
3	Hogares de 1 a 19 miembros	1 a 15 miembros	Corregir el rango
4	PET de 29.985 y 4.821 adultos mayores	PET de 29.953 y 5.166 de 60 años o más	Alinear con la bitácora
5	18 vacíos de *aestudio* imputados con alfabetismo y mediana	0 vacíos reales; los 2.143 eran menores de 4 años	Retirar el texto del resumen del Bloque 3
6	Resumen del Bloque 0: vacíos de *ylab* de 24.964, *tothrs* de 24.942 y *aestudio* de 2.425	22.788, 20.018 y 2.143	Reescribir la tabla de métricas
7	*run_all.R* ejecuta 33 scripts	9 rutas no existen (scripts 00 a 03 y la carpeta del bloque 5 con otro nombre)	Corregir las rutas (sección 6.3)
8	README: "Bloque 0 completo"	Los seis bloques están completos	Actualizar el README y *docs*
9	Distribuciones de *ylab* "idénticas" (informe 24)	Los imputados se desplazan a valores bajos	Ver la sección 5.8
10	*persona_limpio_codificado.csv* como versión codificada	Idéntico en tamaño a *persona_limpio.csv*: no hay factores que convertir	Eliminarlo o construir la versión codificada real

Nota. Elaboración propia con base en los informes de *07_informes*, los resúmenes por bloque, *run_all.R*, *README.md* y *persona_limpio.csv*.

El punto 9 es el más importante y recibe tratamiento aparte. Los puntos 1 a 6 se explican porque el texto de los informes fue escrito, o generado, con cifras de una versión anterior de los scripts; la bitácora, que se escribe en cada ejecución, es consistente con los datos. La lección práctica es que las cifras de los informes deberían escribirse desde el propio script (como ya hace la bitácora) y no a mano.

5.8 Resultados globales y análisis de sensibilidad

De las 10.861.675 celdas originales, 6.261.409 estaban vacías (57,65%). En la base final quedan 6.216.360 vacías (53,53% de las 11.612.118 celdas de la base de 294 columnas). La diferencia de 45.049 celdas se explica así: 42.459 recodificadas a cero por ser estructurales, 20 vacíos de *totper*, 20 de *yhog*, 20 de *yhogpc*, 20 de *p0* y 20 de *pext0* reconstruidos, y 2.490 ingresos imputados. La Tabla 21 desglosa las celdas completadas.

Tabla 21
Celdas completadas en la base y método de relleno

Variable	Celdas	Naturaleza	Método
ylab	20.298	Vacío estructural	Recodificación a 0 Bs
tothrs	20.018	Vacío estructural	Recodificación a 0 horas
aestudio	2.143	Vacío estructural	Recodificación a 0 años
ylab	2.490	Vacío real (aparente)	Imputación PMM con $m = 1$
totper, *yhog*, *yhogpc*, *p0*, *pext0*	100 (20 por variable)	Vacío real	Conteo por hogar y cálculo posterior
Total	**45.049**		

Nota. Elaboración propia con base en la comparación entre *persona.csv* y *persona_limpio.csv*.

Resta valorar el efecto de la imputación sobre la pobreza, que es el indicador que la base está pensada para estimar. La Tabla 22 compara tres versiones: la base original, la base final y una versión de sensibilidad construida a partir de la final en la que se mantiene en 0 el ingreso de los ocupados de las categorías 6 y 7 en lugar de imputarlo. Además, se muestran las tasas ponderadas con el factor de expansión.

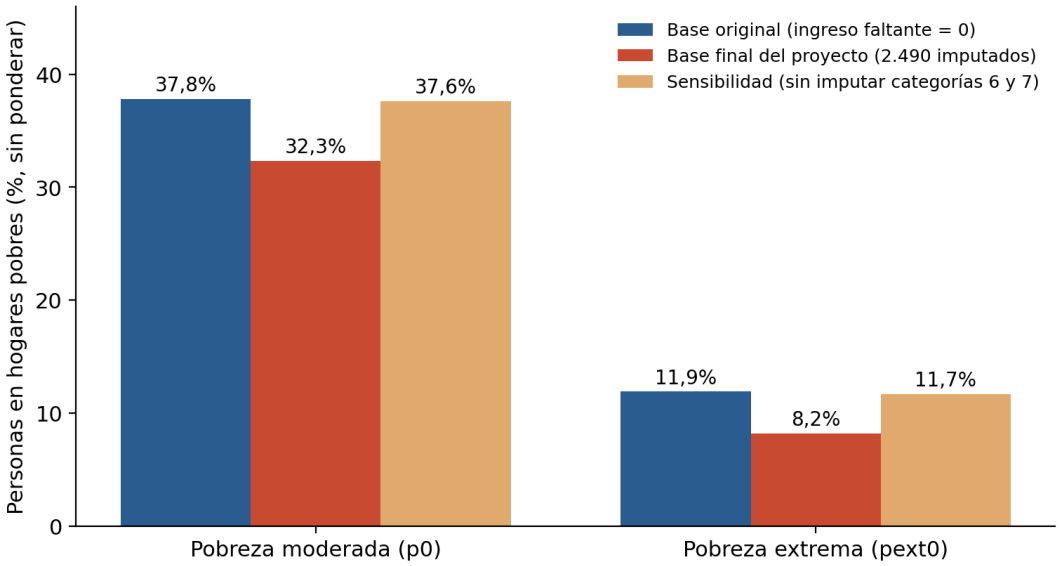
Tabla 22
Tasas de pobreza según el tratamiento del ingreso laboral faltante

Indicador	Base original	Base final	Sensibilidad (sin imputar categorías 6 y 7)
Pobreza moderada, sin ponderar	37,8%	32,3%	37,6%
Pobreza extrema, sin ponderar	11,9%	8,2%	11,7%
Pobreza moderada, ponderada	37,6%	31,6%	37,5%
Pobreza extrema, ponderada	12,8%	8,3%	12,6%

Nota. Elaboración propia con base en *persona.csv* y *persona_limpio.csv*. La base original tiene 20 filas sin indicador de pobreza, que se excluyen del cálculo. Ponderación con la columna *factor*.

Figura 20

Pobreza moderada y extrema según el tratamiento del ingreso laboral faltante



Nota. Elaboración propia con base en *persona.csv* y *persona_limpio.csv*. Tasas sin ponderar.

El resultado es contundente. La base final reduce la pobreza moderada de 37,8% a 32,3%, una caída de 5,5 puntos, y la extrema de 11,9% a 8,2%. Pero si se evita imputar ingreso a las categorías en las que casi nadie lo declara, la pobreza moderada vuelve a 37,6%, a 0,2 puntos de la original. Es decir, casi toda la caída se debe a la imputación de esas 2.389 personas, y no a la corrección de errores reales de la base. La explicación es sencilla: la base original trataba el vacío como cero (en la columna *yper* el cálculo de la fila original coincide con *ylab* vacío igual a cero en 100% de los casos), mientras que la imputación les asignó un ingreso mediano de unos 1.500 Bs, que sumado al del hogar saca a muchos de la pobreza.

Ninguna de las dos versiones es "la verdadera": si esas personas realmente tienen un ingreso que no declararon, la base final se acerca más a la realidad; si trabajan sin remuneración, la original (o la de sensibilidad) es la correcta. Lo que sí es claro es que la decisión no puede tomarse sin confirmar en la boleta qué significan las categorías 6 y 7, y que la base final no debería usarse para estimar pobreza mientras esa pregunta siga abierta. Las demás correcciones (tamaño del hogar, diccionario, ceros estructurales y cotas) no dependen de esa decisión.

6. El repositorio en GitHub

Todo el trabajo vive en un repositorio de GitHub (https://github.com/Manolodev-web/Dat253_Proyecto1). Este capítulo explica qué contiene, cómo se organizó el trabajo en Git, cómo reproducirlo y cómo reutilizar sus informes.

6.1 Qué contiene

Tabla 23
Contenido del repositorio de GitHub

Elemento	Cantidad	Descripción
Scripts de limpieza (*05_scripts*)	33	Scripts 00 a 32, más un script de instalación de dependencias
Informes técnicos (*07_informes/01_tecnicos*)	33	Uno por script, con encabezado de metadatos
Resúmenes por bloque (*07_informes/02_resumenes*)	6	Puntos clave, métricas antes y después, evidencias
Figuras (*06_images*)	17	Gráficos PNG, uno por script de diagnóstico o resultado
Bitácora (*04_bitacora*)	38 filas	12 columnas; 33 pasos y algunas repeticiones
Metadatos (*03_data/04_metadatos*)	3	*diccionario_corregido*, *diccionario_final* y *reglas_saltos*
Productos (*03_data/03_processed*)	3	*persona_limpio* en RDS y CSV, y *persona_limpio_codificado*
Código total	3.929 líneas	Suma de los scripts de *05_scripts*

Nota. Elaboración propia con base en el contenido del repositorio *Dat253_Proyecto1*.

Además del contenido anterior, el repositorio conserva los restos de la primera versión del Bloque 0 (carpetas *scripts*, *informes*, *data*, *images*, *R*, *config*, *bitacora* y *docs*), que conviene archivar o eliminar para evitar confusión (sección 9).

6.2 Cómo se organiza el trabajo en Git

El historial tiene un commit por avance importante, y desde el 3 de octubre uno por bloque (Tabla 24). Esa disciplina permite volver al estado de cualquier bloque y ver qué cambió. El archivo *.gitignore* excluye los checkpoints intermedios (`03_data/02_interim/*.rds`), pesados y regenerables, así como los archivos temporales de R. El archivo *.gitattributes* normaliza los saltos de línea. El repositorio no usa ramas ni etiquetas de versión; trabaja directamente sobre *main*.

Tabla 24
Historial de commits del repositorio

Fecha y hora	Mensaje del commit	Contenido
1 oct. 2026, 09:48	Clonado del repositorio vacío	Inicio
1 oct. 2026, 22:53	Primer avance	Primera versión del Bloque 0
3 oct. 2026, 01:00	Estructura del proyecto, configuración base y funciones auxiliares	Carpetas numeradas, *packages.R*, *funciones.R*
3 oct. 2026, 06:47	Trabajo del Bloque 1	Scripts 08 a 11
3 oct. 2026, 11:13	Bloque 2 Salud	Scripts 12 a 16
3 oct. 2026, 12:59	Bloque 3	Scripts 17 a 21
3 oct. 2026, 15:44	Bloque 4	Scripts 22 a 27
3 oct. 2026, 16:40	Bloque 5	Scripts 28 a 32
3 oct. 2026, 22:12	Actualización scripts	Versión final de scripts, informes y productos

Nota. Elaboración propia con base en el registro de Git (*.git/logs/HEAD*). Horas en zona UTC−4.

6.3 Cómo reproducirlo

Para reproducir el proyecto hacen falta R, los paquetes *readr*, *dplyr*, *tidyr*, *ggplot2*, *Hmisc* y *mice*, y el archivo *persona.csv* en *03_data/01_raw*. El orquestador *run_all.R* ejecuta los scripts en orden, pero tiene nueve rutas que no existen, por lo que debe corregirse antes de usarlo (sección 5.7). Mientras tanto basta con ejecutar los scripts de *05_scripts* en orden numérico, sin saltar ninguno, porque cada uno lee el checkpoint del anterior. El Apéndice F detalla los pasos. Una advertencia sobre el paso 24: PMM es un método aleatorio, y la semilla 253 fija el resultado solo si se ejecuta con las mismas versiones de R y de *mice*.

6.4 Cómo leer y reutilizar los informes

Cada informe técnico empieza con un encabezado YAML que indica el script, la fase, el archivo de entrada, el de salida, la figura y el estado, seguido de cuatro secciones: contexto y diagnóstico, justificación teórica, algoritmo y procedimiento, y métricas de impacto. El índice *00_indice.json* lista los informes y su estado. Los resúmenes por bloque resumen los puntos clave, las métricas de transformación y las evidencias gráficas. Como las cifras de los informes deben verificarse (sección 5.7), conviene tomar como referencia la bitácora y los datos.

7. Discusión

El trabajo confirma una idea sencilla con consecuencias grandes: en una encuesta con saltos de cuestionario, la mayor parte de los vacíos no son datos perdidos. En las cuatro variables clasificadas, los vacíos estructurales son 100% en *tothrs*, *aestudio* y *s02b_06*, y 89,1% en *ylab* (20.298 de 22.788; los otros 2.490 se juzgaron reales). Rellenar esas celdas con promedios o con valores de modelos habría producido cifras absurdas (horas trabajadas de un niño de 3 años) o sesgadas. La recodificación a cero, acompañada de la clasificación, es una solución barata y reversible.

La reconstrucción del tamaño del hogar y la corrección del diccionario son los aportes menos vistosos y más seguros del proyecto. Se apoyan en datos que no admiten discusión (el conteo de filas por hogar, el rango de valores de cada columna) y se verifican con identidades. Las aserciones de cada bloque y la certificación global funcionaron como una red de seguridad: ninguna regla se rompió, y eso permite confiar en la coherencia interna de la base.

Pero la parte más instructiva es la que no resultó. Las aserciones comprueban que las reglas que uno se impone se cumplen, no que las reglas sean correctas. El script 32 certificó con cero fallas una base en la que 95,9% de los ingresos imputados corresponde a categorías que casi no tienen ingreso, y la certificación no podía detectarlo, porque lo que faltaba no era un control sino una pregunta previa: ¿ese vacío es real? El proyecto la formuló bien para las cuatro variables clasificadas, pero para *ylab* la aplicó con un criterio demasiado amplio (cualquier ocupado sin ingreso es una omisión). La primera versión del Bloque 0, que deducía las reglas de los datos, la había contestado mejor: 148 vacíos reales, no 2.490.

Hay otros límites. Primero, PMM se usó con $m = 1$, de modo que los valores imputados se tratan como observados y la incertidumbre de haber imputado no se transmite a los indicadores; para estimar la pobreza con rigor convendría generar varias imputaciones (por ejemplo, 20) y combinarlas con las reglas de Rubin. Segundo, el modelo no incluyó la categoría ocupacional *s04b_12*, que es el mejor predictor de que el ingreso exista. Tercero, solo se clasificaron cuatro variables; el resto de las 275 columnas conserva sus vacíos sin una etiqueta que los distinga, de modo que quien use la base no puede saber, por ejemplo, si un vacío en una pregunta de salud es estructural o real. Cuarto, algunas decisiones se basaron en supuestos sobre códigos que no se confirmaron con la boleta (Apéndice E). Finalmente, la documentación contiene cifras

desactualizadas (sección 5.7), lo que debilita una de las fortalezas del proyecto, que es la trazabilidad.

Con esos límites, el resultado puede resumirse así: la base final es más coherente que la original en el tamaño del hogar, el diccionario y los ceros estructurales, y es menos confiable que la original en el ingreso y la pobreza hasta que se resuelva la cuestión de las categorías 6 y 7. Esa distinción es el hallazgo central de la discusión, y se obtuvo gracias a que el proyecto dejó banderas de linaje y una base original contra la cual comparar.

8. Conclusiones

3. **La mayor parte de los vacíos son estructurales.** De los 6.261.409 vacíos originales, se identificaron y recodificaron a cero 42.459 estructurales en escolaridad, horas e ingreso laboral. En las variables clasificadas, solo 2.490 vacíos se consideraron reales, todos de ingreso laboral.
4. **El diccionario y el tamaño del hogar eran incorrectos.** Se corrigieron tres columnas permutadas (*sexo*, *edad* y *parentesco*) y se reconstruyó *totper*, que valía 1 en 39.477 filas; los hogares tienen entre 1 y 15 miembros y 3,11 en promedio.
5. **La integridad básica de la base es sólida.** No hay duplicados, la llave (*folio*, *nro*) es única, cada uno de los 12.718 hogares tiene un solo jefe y las identidades contables de ingreso se cumplen en el 100% de las filas de la base final.
6. **Los bloques de salud, educación y no laboral no requirieron imputación.** Las variables revisadas no tenían vacíos reales; se agregaron variables derivadas útiles (*gasto_salud_total*, *uso_internet*, *clima_educativo_hogar*, *ingreso_horario* y banderas de jornada y de salario).
7. **La imputación de ingresos debe rehacerse.** El 95,9% de los 2.490 ingresos imputados corresponde a dos categorías ocupacionales en las que 97,7% a 99,5% de los ocupados no declara ingreso, y 251 imputaciones valen 0 porque el universo del modelo incluyó a 280 niños recodificados. La pobreza moderada pasa de 37,8% a 32,3% con esa imputación y vuelve a 37,6% sin ella.
8. **Clasificar importa más que imputar.** La pregunta "¿esta celda debía tener un dato?" tiene más efecto sobre los resultados que la elección del algoritmo de imputación.
9. **La reproducibilidad es alta pero mejorable.** El proyecto deja numeración, bitácora, banderas de linaje, checkpoints y control de versiones; falta corregir *run_all.R*, actualizar las cifras de los informes y archivar la primera versión del Bloque 0.

9. Recomendaciones

- **Confirmar con la boleta oficial** el significado de las categorías 6 y 7 de *s04b_12*, de los códigos de *cobersalud* y *condact*, y de la pregunta de internet (Apéndice E). Es la condición para decidir el tratamiento del ingreso.
- **Rehacer la imputación del script 24** con tres cambios: excluir del universo a los menores fuera de la PET; clasificar como vacío estructural (o dejar sin imputar) a las categorías sin ingreso por diseño; e incluir *s04b_12* como predictor.
- **Usar imputación múltiple de verdad** ($m \geq 20$) y combinar los resultados con las reglas de Rubin, o al menos presentar la pobreza con y sin imputación, como en la Tabla 22.
- **Extender la clasificación estructural/real a todas las variables con vacíos**, no solo a cuatro, y guardar una columna o máscara por variable. La primera versión del Bloque 0 ya tiene un algoritmo para hacerlo y puede reaprovecharse tras revisar sus reglas.
- **Generar las cifras de los informes desde el código** y no escribirlas a mano, de modo que informes y bitácora no puedan divergir.
- **Corregir el orquestador** (`run_all.R`) y archivar o eliminar las carpetas de la primera versión; actualizar el *README* y *docs*.
- **Eliminar o rehacer la versión codificada** (`persona_limpio_codificado.csv`), hoy idéntica a *persona_limpio.csv*.
- **Ponderar con el factor de expansión** cuando se estimen tasas para la población, y reportar los intervalos de confianza.
- **Agregar al repositorio etiquetas de versión** (por ejemplo, *v1.0-bloques0-5* tras la corrección de ingresos) para que cada entrega quede congelada.

Referencias

Bolivia. (2007). *Ley N.º 3791: Renta Universal de Vejez (Renta Dignidad)*. Gaceta Oficial del Estado Plurinacional de Bolivia.

Bolivia. (2024). *Decreto Supremo N.º 5154, de 1 de mayo de 2024*. Gaceta Oficial del Estado Plurinacional de Bolivia. https://www.lexivox.org/norms/BO-DS-N5154.html

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Fayyad, U., Piatetsky-Shapiro, G., y Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine, 17*(3), 37-54.

Foster, J., Greer, J., y Thorbecke, E. (1984). A class of decomposable poverty measures. *Econometrica, 52*(3), 761-766.

Han, J., Kamber, M., y Pei, J. (2012). *Data mining: Concepts and techniques* (3.ª ed.). Morgan Kaufmann.

Instituto Nacional de Estadística [INE]. (2024). *Encuesta de Hogares 2024: base de datos persona y diccionario*. Estado Plurinacional de Bolivia. https://www.ine.gob.bo

Little, R. J. A. (1988). Missing-data adjustments in large surveys. *Journal of Business & Economic Statistics, 6*(3), 287-296.

Little, R. J. A., y Rubin, D. B. (2019). *Statistical analysis with missing data* (3.ª ed.). Wiley.

R Core Team. (2024). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing. https://www.R-project.org/

Rubin, D. B. (1976). Inference and missing data. *Biometrika, 63*(3), 581-592.

Rubin, D. B. (1986). Statistical matching using file concatenation with adjusted weights and multiple imputations. *Journal of Business & Economic Statistics, 4*(1), 87-94.

Rubin, D. B. (1987). *Multiple imputation for nonresponse in surveys*. Wiley.

Sandve, G. K., Nekrutenko, A., Taylor, J., y Hovig, E. (2013). Ten simple rules for reproducible computational research. *PLoS Computational Biology, 9*(10), e1003285.

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

van Buuren, S. (2018). *Flexible imputation of missing data* (2.ª ed.). CRC Press.

van Buuren, S., y Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software, 45*(3), 1-67.

Wickham, H. (2016). *ggplot2: Elegant graphics for data analysis*. Springer.

Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., François, R., … Yutani, H. (2019). Welcome to the tidyverse. *Journal of Open Source Software, 4*(43), 1686.

Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., Appleton, G., Axton, M., Baak, A., … Mons, B. (2016). The FAIR guiding principles for scientific data management and stewardship. *Scientific Data, 3,* 160018.

Apéndice A. Glosario

Tabla 25
Glosario de términos

Término	Significado
Aserción (*stopifnot*)	Condición que el código verifica; si no se cumple, el proceso se detiene
Bandera de linaje	Columna 0/1 que indica si un valor fue modificado o imputado (*ylab_imputado*)
Bitácora	Archivo que registra cada operación de limpieza con fecha, acción y justificación
Checkpoint	Copia del estado de la base tras cada script (*persona_NN.rds*)
Condición de actividad (*condact*)	Situación laboral de la persona: ocupada, desocupada u otras
Factor de expansión (*factor*)	Peso que permite proyectar la muestra a la población
Fail-fast	Principio de detener el proceso en cuanto se detecta un error
FGT	Familia de medidas de pobreza de Foster, Greer y Thorbecke
Imputación	Completar un valor faltante con una estimación
MICE	Imputación por ecuaciones encadenadas (paquete *mice* de R)
PEA / PET	Población económicamente activa / población en edad de trabajar (14 años o más)
PMM	*Predictive mean matching*: imputa copiando el valor de un donante con predicción cercana
Pobreza moderada / extrema	Ingreso per cápita del hogar menor que *z* / menor que *zext*
Salto de cuestionario	Instrucción que omite ciertas preguntas según las respuestas o la edad
Sensibilidad (análisis de)	Repetir un cálculo cambiando un supuesto para ver cuánto cambia el resultado
SMN	Salario Mínimo Nacional (Bs 2.500 en 2024)
Vacío estructural	Celda vacía porque la pregunta no correspondía a la persona
Vacío real	Celda vacía de una persona que debía responder
Winsorización	Limitar un valor extremo a una cota en lugar de eliminarlo

Nota. Elaboración propia.

Apéndice B. Variables trabajadas por bloque

Tabla 26

Variables originales y variables añadidas por bloque

Bloque	Variables originales clave	Variables añadidas
0 Global	*s01a_02*, *s01a_03*, *s01a_05*, 14 columnas de texto, *folio*, *nro*	*sexo*, *edad*, *parentesco*, 4 *tipo_na_*, 3 *_imputado*
1 Vivienda	*totper*, *tipohogar*, *yhog*, *yhogpc*, *z*, *zext*, *p0*, *pext0*	Ninguna (se reemplaza *totper*)
2 Salud	*cobersalud*, *s02a_01a*, *s02a_03a-e*, *s02a_04a-f*, *s02b_06*, *hnv_ult_a*	*cobersalud_imputado*, *gasto_salud_total*
3 Educación	*aestudio*, *niv_ed*, *niv_ed_g*, *s03a_01*, *s03c_14*	*uso_internet*, *clima_educativo_hogar*
4 Empleo	*condact*, *pet*, *s04b_12*, *tothrs*, *ylab*	*debajo_smn*, *ingreso_horario*, *subempleo_horario*, *sobreempleo_horario*
5 Cierre	*s05a_01e*, *s05a_01e0*, *ynolab*, *yper*	*ynolab_imputado*
Total	**275 columnas originales**	**19 columnas (294 en total)**

Nota. Elaboración propia con base en *diccionario_final.csv* y la comparación de columnas entre *persona.csv* y *persona_limpio.csv*.

Apéndice C. Los 33 scripts, uno por uno

Tabla 27

Los 33 scripts del proyecto

N.º	Nombre	Qué hace	Filas afect.
00	Auditoría inicial	Perfilado de vacíos y tipos	0
01	Diccionario corregido	Crea *sexo*, *edad*, *parentesco*	39.497
02	Tipos, unarias y etiquetas	Coerción de tipos y etiquetas	39.497
03	Normalizar texto	Mayúsculas, sin tildes, vacío a NA	37
04	Duplicados e integridad	Llave y jefatura única	0
05	Reglas de salto	Nueve universos	39.497
06	Clasificar NA	Estructural frente a real	39.497
07	Recodificar estructurales	42.459 celdas a 0 y banderas	20.298
08	Vivienda: diagnóstico	Detecta *totper* aplanado	10.285
09	Vivienda: *totper* y tipo de hogar	Reconstruye *totper*	37.064
10	Vivienda: ingreso y pobreza	Verifica *yhogpc*, *z*, *zext*, *p0*	45
11	Vivienda: validación	Cinco aserciones	0
12	Salud: diagnóstico	Cobertura y fecundidad	0
13	Salud: nulos	Sin vacíos que tratar	0
14	Salud: saltos de fecundidad	Filtro biológico	0
15	Salud: gastos de bolsillo	Crea *gasto_salud_total*	39.497
16	Salud: validación	Cuatro aserciones	0
17	Educación: diagnóstico	Universo de 4 años o más	0
18	Educación: nulos y alfabetismo	Sin vacíos reales	0
19	Educación: consistencia biológica	Cota edad − 4	3
20	Educación: TIC y sintéticas	*uso_internet*, *clima_educativo_hogar*	39.497
21	Educación: validación	Cinco aserciones	0
22	Empleo: diagnóstico	PET, PEA, TGP, TD	2.490
23	Empleo: horas trabajadas	Cota de 112 horas	29
24	Empleo: imputación con mice	PMM de *ylab*	2.490
25	Empleo: salario mínimo	*debajo_smn*	39.497
26	Empleo: ingreso horario	*ingreso_horario* y jornadas	39.497
27	Empleo: validación	Seis aserciones	0
28	No laboral: diagnóstico	Renta Dignidad	0
29	No laboral: saltos	Sin cambios	0
30	Ingreso total y pobreza	*yper*, *yhog*, *yhogpc*, *p0*, *pext0*	39.497
31	Exportar dataset final	RDS, CSV, diccionario	39.497
32	Certificación global	Aserciones maestras	39.497

Nota. Elaboración propia con base en *05_scripts* y la bitácora. Las filas afectadas son las registradas en la bitácora.

Apéndice D. Extracto de la bitácora de limpieza

Tabla 28

Primeras filas de la bitácora de limpieza

Paso	Fecha y hora	Atributo	Acción realizada	Filas
0	2026-10-02 23:02	Global (275 columnas)	Perfilado; 6.261.409 vacíos (57,65%)	0
1	2026-10-02 23:09	*s01a_02*, *s01a_03*, *s01a_05*	Reconciliación con el catálogo; crea *sexo*, *edad*, *parentesco*	39.497
2	2026-10-02 23:17	*folio*, *upm*, *estrato*…	Coerción de identificadores y etiquetado	39.497
3	2026-10-02 23:18	14 columnas de texto	Espacios, mayúsculas, tildes, vacío a NA	37
4	2026-10-02 23:21	*folio*, *nro*, *parentesco*	0 duplicados; 12.718 jefes únicos	0
5	2026-10-02 23:23	Reglas de salto	Nueve reglas; exporta *reglas_saltos.csv*	39.497
6	2026-10-02 23:27	Cuatro *tipo_na_*	Observado, estructural o real	39.497
7	2026-10-02 23:28	*aestudio*, *tothrs*, *ylab*	Ceros lógicos y banderas	20.298
9	2026-10-03 00:20	*totper*, *tipohogar*	Reconstruye *totper* por conteo de folio	37.064
24	2026-10-03 00:46	*ylab*, *ylab_imputado*	PMM de 2.490 ingresos; 8 predictores; semilla 253	2.490
30	2026-10-03 00:53	*yper*, *yhog*, *yhogpc*, *p0*	Reconstrucción contable; p0 = 32,34%, pext0 = 8,18%	39.497
32	2026-10-03 00:53	Certificación global	Aserciones maestras superadas	39.497

Nota. Elaboración propia con base en *04_bitacora/bitacora_limpieza.csv*. El archivo completo tiene 38 filas.

Apéndice E. Hipótesis y reglas por confirmar con la boleta

Tabla 29

Hipótesis y supuestos deducidos de los datos

N.º	Hipótesis o supuesto	Evidencia	Qué confirmar
1	Las categorías 6 y 7 de *s04b_12* no reciben ingreso por diseño (por ejemplo, trabajo familiar no remunerado)	99,5% y 97,7% de ocupados de la PET sin *ylab*	Etiquetas de *s04b_12* en la boleta
2	*s01a_02*, *s01a_03* y *s01a_05* son sexo, edad y parentesco	Rango y valores de cada columna	Catálogo DDI del INE (no está en el repositorio)
3	El código 4 de *cobersalud* podría ser "ninguno" y no "otro seguro"	Solo existen los códigos 1 a 4; el script supone 1 a 5	Etiquetas de *cobersalud*
4	*s03c_14* es el uso de internet	Primera columna de una lista de candidatas	Pregunta exacta de la sección 3-C
5	Los códigos 3, 4 y 5 de *condact* son categorías de inactividad y búsqueda	El diccionario solo describe tres códigos	Códigos de *condact*
6	Los 296 niños de 7 a 13 años ocupados están fuera de la PET y su ingreso es 0 o vacío	280 con *ylab* vacío	Si se les hace la sección de empleo
7	La Renta Dignidad aplica desde los 60 años	Ley 3791; 0 casos menores de 60	Ninguno: respaldado por la norma
8	El SMN de 2024 es de Bs 2.500	Decreto Supremo 5154	Ninguno: respaldado por la norma

Nota. Elaboración propia.

Apéndice F. Cómo reproducir el proyecto

Tabla 30

Pasos para reproducir el proyecto

Paso	Acción	Comentario
1	Clonar el repositorio desde GitHub	*git clone https://github.com/Manolodev-web/Dat253_Proyecto1.git*
2	Verificar que *03_data/01_raw/persona.csv* exista	Son 34,6 MB; está versionado
3	Instalar los paquetes con *01_config/packages.R*	readr, dplyr, tidyr, ggplot2, Hmisc, mice
4	Abrir RStudio en la carpeta raíz del proyecto	Los scripts buscan la carpeta *03_data* hacia arriba
5	Corregir las nueve rutas de *run_all.R*, o ejecutar los scripts de *05_scripts* en orden 00 a 32	Cada script lee el checkpoint del anterior
6	Revisar *04_bitacora/bitacora_limpieza.csv*	Al reejecutar se agregan filas; vaciarla antes si se desea un registro limpio
7	Obtener los productos en *03_data/03_processed*	*persona_limpio.rds* y *.csv*
8	Para corregir la imputación, modificar el script 24 según la sección 9	Reejecutar desde el 24 en adelante

Nota. Elaboración propia.

Apéndice G. Diccionario de datos completo de persona_limpio

Este apéndice describe las 294 columnas de la base final *persona_limpio* (275 originales y 19 añadidas). Se generó a partir de la propia base y de los archivos *diccionario_final.csv*, *diccionario_corregido.csv* y *Diccionario de Persona.docx*, de modo que los porcentajes de vacíos y los rangos son los reales y no los declarados. Hay que leerlo con tres advertencias.

- **Descripciones verificadas y descripciones por rango.** Las columnas clave (identificadores, demografía, hogar, pobreza, salud, educación, empleo, ingresos y todas las añadidas) tienen una descripción individual contrastada con los datos. Las 224 marcadas con † solo tienen la descripción de su parte del cuestionario (por ejemplo, "Empleo: ingresos de la ocupación principal"), tomada del diccionario Word, que describe grupos de preguntas y no cada una. Para conocer el enunciado exacto de esas preguntas hace falta la boleta.
- **El diccionario Word no es del todo confiable.** Ya se demostró que describe mal *s01a_02*, *s01a_03* y *s01a_05* (sección 5.1.2) y también atribuye la parte *s02b* a la discapacidad, cuando los datos y los scripts la tratan como fecundidad y embarazo. Donde hubo contradicción se prefirió lo observado en los datos.
- **Los vacíos finales casi no cambian respecto a los originales.** Un porcentaje alto no indica un defecto: casi siempre es un vacío estructural, es decir, una pregunta que no correspondía a la persona (sección 3.5). Solo cambian *totper*, *yhog*, *yhogpc*, *p0*, *pext0*, *tothrs*, *ylab* y *aestudio*.

Cómo leer la tabla: **Tipo** es el tipo de dato (Entero, Decimal o Texto); **Bloque** es el bloque temático (Viv = vivienda y hogar, S1 a S5 = secciones de la encuesta, Clasif. = columnas *tipo_na_*, Deriv. = variables derivadas); **% vac. orig.** y **% vac. final** son los porcentajes de celdas vacías antes y después de la limpieza (— indica columna añadida); y **Valores** es el rango de las numéricas, los valores posibles cuando son uno o dos, o el número de valores distintos entre paréntesis para el texto.

Tabla 31

Diccionario de datos completo de la base persona_limpio (294 variables)

N.º	Variable	Tipo	Bloque	Descripción	% vac. orig.	% vac. final	Valores
1	folio	Texto	Viv	Identificador único del hogar (llave junto con nro)	0,0	0,0	texto (12718)
2	area	Entero	Viv	Área geográfica (1 urbana, 2 rural)	0,0	0,0	1 / 2
3	depto	Entero	Viv	Departamento (1 Chuquisaca … 9 Pando)	0,0	0,0	1 a 9
4	nro	Entero	S1	Número de orden de la persona en el hogar	0,0	0,0	1 a 15
5	s01a_02	Entero	S1	Sexo (1 hombre, 2 mujer); el diccionario Word lo describe como parentesco	0,0	0,0	1 / 2
6	s01a_03	Entero	S1	Edad en años cumplidos (0 a 98); el Word lo describe como sexo	0,0	0,0	0 a 98
7	s01a_04a	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	0,0	0,0	1 a 31
8	s01a_04b	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	0,0	0,0	1 a 12
9	s01a_04c	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	0,0	0,0	1.926 a 2.024
10	s01a_05	Entero	S1	Parentesco con el jefe o jefa del hogar (1 a 14); el Word lo describe como edad	0,0	0,0	1 a 14
11	s01a_05a	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	20,2	20,2	0 a 12
12	s01a_05b	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	0,0	0,0	0 a 11
13	s01a_05c	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	0,0	0,0	0 a 12
14	s01a_06	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	78,2	78,2	1 a 25
15	s01a_07_1	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	0,0	0,0	2 a 996
16	s01a_07_2	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	73,0	73,0	2 a 58
17	s01a_07_3	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	98,6	98,6	2 a 60
18	s01a_08	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	3,7	3,7	2 a 58
19	s01a_09	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	0,0	0,0	1 / 2
20	s01a_09npioc	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	77,0	77,0	1 a 993
21	s01a_10	Entero	S1	Sociodemografía: nacimiento, estado civil, pertenencia indígena, idioma †	20,2	20,2	1 a 6
22	s01b_11a	Entero	S1	Migración y lugar de residencia 5 años atrás †	0,0	0,0	1 a 4
23	s01b_11b	Entero	S1	Migración y lugar de residencia 5 años atrás †	96,0	96,0	1 a 9
24	s01b_11c	Entero	S1	Migración y lugar de residencia 5 años atrás †	96,0	96,0	101 a 905
25	s01b_11d	Entero	S1	Migración y lugar de residencia 5 años atrás †	96,0	96,0	10.101 a 90.501
26	s01b_11e	Entero	S1	Texto libre «especifique»: Migración y lugar de residencia 5 años atrás †	99,6	99,6	32 a 862
27	s01b_12	Entero	S1	Migración y lugar de residencia 5 años atrás †	95,6	95,6	1 a 6
28	s01b_12e	Texto	S1	Texto libre «especifique»: Migración y lugar de residencia 5 años atrás †	100,0	100,0	texto (17)
29	s01b_13a	Entero	S1	Migración y lugar de residencia 5 años atrás †	95,6	95,6	2.019 a 2.024
30	s01b_13b	Entero	S1	Migración y lugar de residencia 5 años atrás †	95,6	95,6	1 a 12
31	s02a_01a	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 a 5

N.º	Variable	Tipo	Bloque	Descripción	% vac. orig.	% vac. final	Valores
32	s02a_01b	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	99,8	99,8	1 a 3
33	s02a_01e	Texto	S2	Texto libre «especifique»: Salud: dolencias, atención, gasto y dificultades permanentes †	100,0	100,0	texto (1)
34	s02a_02a	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 / 2
35	s02a_02b	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 / 2
36	s02a_02c	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 / 2
37	s02a_02d	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 / 2
38	s02a_02e	Entero	S2	Texto libre «especifique»: Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 / 2
39	s02a_02f	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 / 2
40	s02a_02g	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 / 2
41	s02a_02h	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 / 2
42	s02a_02he	Texto	S2	Texto libre «especifique»: Salud: dolencias, atención, gasto y dificultades permanentes †	100,0	100,0	texto (4)
43	s02a_03a	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	0 a 50.000
44	s02a_03b	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	0 a 100.000
45	s02a_03c	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	0 a 50.000
46	s02a_03d	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	0 a 96.000
47	s02a_03e	Entero	S2	Texto libre «especifique»: Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	0 a 84.000
48	s02a_04a	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 a 4
49	s02a_04b	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 a 4
50	s02a_04c	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 a 4
51	s02a_04d	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	0,0	0,0	1 a 4
52	s02a_05	Entero	S2	Salud: dolencias, atención, gasto y dificultades permanentes †	89,7	89,7	1 a 4
53	s02b_06	Entero	S2	Embarazo actual (universo: mujeres de 13 a 50 años)	71,3	71,3	1 a 3
54	s02b_06b	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	83,7	83,7	1 a 15
55	s02b_07	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	83,7	83,7	0 a 15
56	s02b_08	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	84,0	84,0	0 a 12
57	s02b_09a	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	84,0	84,0	1 a 12
58	s02b_09b	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	84,0	84,0	1.981 a 2.024
59	s02b_10	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	93,1	93,1	1 a 8
60	s02b_10e	Texto	S2	Texto libre «especifique»: Fecundidad y embarazo (mujeres en edad fértil) †	100,0	100,0	texto (2)

N.º	Variable	Tipo	Bloque	Descripción	% vac. orig.	% vac. final	Valores
61	s02b_11	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	83,7	83,7	1 / 2
62	s02b_12a1	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	92,2	92,2	1 / 2
63	s02b_12a2	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	99,0	99,0	1 a 4
64	s02b_12b	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	92,2	92,2	1 / 2
65	s02b_13	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	92,2	92,2	1 / 2
66	s02b_14	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	94,7	94,7	1 / 2
67	s02b_14a	Entero	S2	Fecundidad y embarazo (mujeres en edad fértil) †	99,0	99,0	1 a 4
68	s02c_15	Entero	S2	Control prenatal y desarrollo infantil †	91,3	91,3	1 a 3
69	s02d_16	Entero	S2	Fecundidad, nacimientos y bono para madres/niños †	93,0	93,0	1 / 2
70	s02d_17	Entero	S2	Fecundidad, nacimientos y bono para madres/niños †	95,6	95,6	1 / 2
71	s02d_17a	Entero	S2	Fecundidad, nacimientos y bono para madres/niños †	98,3	98,3	1 a 6
72	s03a_01	Entero	S3	Sabe leer y escribir (1 sí, 2 no); universo de 4 años o más	5,4	5,4	1 / 2
73	s03a_01a	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	5,4	5,4	1 / 2
74	s03a_02a	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	5,4	5,4	11 a 78
75	s03a_02c	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	5,4	5,4	0 a 14
76	s03a_03a	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	94,2	94,2	11 a 65
77	s03a_03c	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	94,2	94,2	0 a 8
78	s03a_04	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	5,4	5,4	1 / 2
79	s03a_05	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	40,5	40,5	1 a 8
80	s03a_05e	Texto	S3	Texto libre «especifique»: Educación: alfabetismo, asistencia, nivel y curso †	99,2	99,2	texto (201)
81	s03a_06a	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	65,0	65,0	12 a 78
82	s03a_06c	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	65,0	65,0	0 a 9
83	s03a_07a	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	73,7	73,7	1 / 2
84	s03a_07b	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	77,9	77,9	1 a 10
85	s03a_08	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	73,7	73,7	1 / 2
86	s03a_09	Entero	S3	Educación: alfabetismo, asistencia, nivel y curso †	65,0	65,0	1 / 2
87	s03b_10	Entero	S3	Educación: tipo de establecimiento y no asistencia †	65,0	65,0	1 a 4
88	s03b_11	Entero	S3	Educación: tipo de establecimiento y no asistencia †	92,8	92,8	1 a 5
89	s03b_11e	Texto	S3	Texto libre «especifique»: Educación: tipo de establecimiento y no asistencia †	99,9	99,9	texto (37)

N.º	Variable	Tipo	Bloque	Descripción	% vac. orig.	% vac. final	Valores
90	s03b_12	Entero	S3	Educación: tipo de establecimiento y no asistencia †	99,9	99,9	1 / 2
91	s03c_13	Entero	S3	Tecnologías de información y comunicación (TIC) †	7,0	7,0	1 / 2
92	s03c_13a	Entero	S3	Tecnologías de información y comunicación (TIC) †	29,2	29,2	1 a 3
93	s03c_14	Entero	S3	Uso de internet (supuesto por confirmar)	7,0	7,0	1 / 2
94	s03c_15a	Entero	S3	Tecnologías de información y comunicación (TIC) †	7,0	7,0	1 / 2
95	s03c_15b	Entero	S3	Tecnologías de información y comunicación (TIC) †	72,6	72,6	1 a 4
96	s03c_16a	Entero	S3	Tecnologías de información y comunicación (TIC) †	7,0	7,0	1 / 2
97	s03c_16b	Entero	S3	Tecnologías de información y comunicación (TIC) †	32,0	32,0	1 a 4
98	s03c_17aa	Entero	S3	Tecnologías de información y comunicación (TIC) †	32,0	32,0	1 a 7
99	s03c_17ab	Entero	S3	Tecnologías de información y comunicación (TIC) †	63,0	63,0	1 a 7
100	s03c_17e	Texto	S3	Texto libre «especifique»: Tecnologías de información y comunicación (TIC) †	99,5	99,5	texto (97)
101	s04a_01	Entero	S4	Empleo: condición de ocupación la última semana †	10,5	10,5	1 / 2
102	s04a_02	Entero	S4	Empleo: condición de ocupación la última semana †	58,5	58,5	1 a 9
103	s04a_02a	Entero	S4	Empleo: condición de ocupación la última semana †	99,4	99,4	1 / 2
104	s04a_03	Entero	S4	Empleo: condición de ocupación la última semana †	59,5	59,5	1 a 10
105	s04a_04	Entero	S4	Empleo: condición de ocupación la última semana †	59,8	59,8	1 / 2
106	s04a_05	Entero	S4	Empleo: condición de ocupación la última semana †	59,8	59,8	1 / 2
107	s04a_06	Entero	S4	Empleo: condición de ocupación la última semana †	62,6	62,6	1 a 6
108	s04a_06e	Texto	S4	Texto libre «especifique»: Empleo: condición de ocupación la última semana †	99,8	99,8	texto (60)
109	s04a_07	Entero	S4	Empleo: condición de ocupación la última semana †	62,6	62,6	1 a 10
110	s04a_07e	Texto	S4	Texto libre «especifique»: Empleo: condición de ocupación la última semana †	99,8	99,8	texto (80)
111	s04a_08	Entero	S4	Empleo: condición de ocupación la última semana †	59,8	59,8	1 / 2
112	s04b_09a_cod	Entero	S4	Empleo: ocupación, tareas y categoría ocupacional †	50,7	50,7	23 a 96.299
113	s04b_10a_cod	Entero	S4	Empleo: ocupación, tareas y categoría ocupacional †	50,7	50,7	1 a 99.002
114	s04b_11aa	Entero	S4	Empleo: ocupación, tareas y categoría ocupacional †	50,7	50,7	1 a 80
115	s04b_11ab	Entero	S4	Empleo: ocupación, tareas y categoría ocupacional †	50,7	50,7	2 a 8
116	s04b_11ba	Entero	S4	Empleo: ocupación, tareas y categoría ocupacional †	50,7	50,7	1 a 80
117	s04b_11bb	Entero	S4	Empleo: ocupación, tareas y categoría ocupacional †	50,7	50,7	2 a 8
118	s04b_12	Entero	S4	Categoría ocupacional (las categorías 6 y 7 casi no declaran ingreso)	50,7	50,7	1 a 8

N.º	Variable	Tipo	Bloque	Descripción	% vac. orig.	% vac. final	Valores
119	s04b_13	Entero	S4	Empleo: ocupación, tareas y categoría ocupacional †	82,1	82,1	1 a 6
120	s04b_14	Entero	S4	Empleo: ocupación, tareas y categoría ocupacional †	51,6	51,6	1 a 3.000
121	s04b_15	Decimal	S4	Empleo: ocupación, tareas y categoría ocupacional †	50,7	50,7	1 a 7
122	s04b_16aa	Entero	S4	Empleo: ocupación, tareas y categoría ocupacional †	50,7	50,7	1 a 24
123	s04b_16ab	Entero	S4	Empleo: ocupación, tareas y categoría ocupacional †	50,7	50,7	0 a 45
124	s04c_17a	Entero	S4	Empleo: actividad económica del negocio †	81,4	81,4	10 a 30.000
125	s04c_17b	Entero	S4	Empleo: actividad económica del negocio †	81,4	81,4	1 a 8
126	s04c_18a	Entero	S4	Empleo: actividad económica del negocio †	81,3	81,3	0 a 40.000
127	s04c_18b	Entero	S4	Empleo: actividad económica del negocio †	81,4	81,4	0 a 65.000
128	s04c_19aa	Entero	S4	Empleo: actividad económica del negocio †	81,3	81,3	0 a 999.999
129	s04c_19ab	Entero	S4	Empleo: actividad económica del negocio †	98,3	98,3	1 a 8
130	s04c_19ba	Entero	S4	Empleo: actividad económica del negocio †	81,3	81,3	0 a 6.000
131	s04c_19bb	Entero	S4	Empleo: actividad económica del negocio †	99,1	99,1	1 a 8
132	s04c_20a1	Entero	S4	Empleo: actividad económica del negocio †	81,3	81,3	1 / 2
133	s04c_20a2	Entero	S4	Empleo: actividad económica del negocio †	99,7	99,7	1 a 12
134	s04c_20b	Entero	S4	Empleo: actividad económica del negocio †	81,3	81,3	1 / 2
135	s04c_20a_1	Entero	S4	Empleo: actividad económica del negocio †	81,3	81,3	1 / 2
136	s04c_20a_2	Entero	S4	Empleo: actividad económica del negocio †	81,3	81,3	1 / 2
137	s04c_21a	Entero	S4	Empleo: actividad económica del negocio †	81,3	81,3	1 / 2
138	s04c_21a1	Entero	S4	Empleo: actividad económica del negocio †	96,3	96,3	1 a 8
139	s04c_21a2	Entero	S4	Empleo: actividad económica del negocio †	96,3	96,3	2 a 4.600
140	s04c_21b	Entero	S4	Empleo: actividad económica del negocio †	81,3	81,3	1 / 2
141	s04c_21b1	Entero	S4	Empleo: actividad económica del negocio †	99,4	99,4	1 a 8
142	s04c_21b2	Entero	S4	Empleo: actividad económica del negocio †	99,4	99,4	2 a 1.100
143	s04c_21c	Entero	S4	Empleo: actividad económica del negocio †	81,3	81,3	1 / 2
144	s04c_21c1	Entero	S4	Empleo: actividad económica del negocio †	98,1	98,1	4 a 8
145	s04c_21c2	Entero	S4	Empleo: actividad económica del negocio †	98,1	98,1	20 a 3.000
146	s04c_21d	Entero	S4	Empleo: actividad económica del negocio †	81,3	81,3	1 / 2
147	s04c_21d1	Entero	S4	Empleo: actividad económica del negocio †	99,2	99,2	1 a 8
148	s04c_21d2	Entero	S4	Empleo: actividad económica del negocio †	99,2	99,2	1 a 12.000
149	s04c_21e	Entero	S4	Texto libre «especifique»: Empleo: actividad económica del negocio †	81,3	81,3	1 / 2
150	s04c_21e1	Entero	S4	Empleo: actividad económica del negocio †	100,0	100,0	1 a 8
151	s04c_21e2	Entero	S4	Empleo: actividad económica del negocio †	100,0	100,0	15 a 500
152	s04d_22a	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,1	76,1	0 a 835.200
153	s04d_22b	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,4	76,4	1 a 8
154	s04d_23aa	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,4	76,4	0 a 821.200
155	s04d_23ab	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	80,3	80,3	1 a 8
156	s04d_23ba	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,4	76,4	0 a 170.520
157	s04d_23bb	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	93,8	93,8	1 a 8
158	s04d_23ca	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,4	76,4	0 a 155.520
159	s04d_23cb	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	98,2	98,2	1 a 8
160	s04d_23da	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,4	76,4	0 a 30.000
161	s04d_23db	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	95,7	95,7	1 a 8
162	s04d_23ea	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,4	76,4	0 a 7.000

N.º	Variable	Tipo	Bloque	Descripción	% vac. orig.	% vac. final	Valores
163	s04d_23eb	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	91,5	91,5	1 a 8
164	s04d_23fa	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,4	76,4	0 a 73.000
165	s04d_23fb	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	99,0	99,0	1 a 8
166	s04d_23ga	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,4	76,4	0 a 20.000
167	s04d_23gb	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	95,2	95,2	1 a 8
168	s04d_23ha	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,4	76,4	0 a 6.000
169	s04d_23hb	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	96,4	96,4	1 a 8
170	s04d_24a	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,1	76,1	0 a 403.180
171	s04d_24b	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	76,4	76,4	1 a 8
172	s04d_24ba	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	94,4	94,4	1 / 2
173	s04d_24bb	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	95,3	95,3	1 a 8
174	s04d_24bc	Entero	S4	Empleo: horas, estabilidad y aportes a AFP †	95,3	95,3	2 a 60.000
175	s04e_25	Entero	S4	Variable documentada en el diccionario Word †	50,7	50,7	1 / 2
176	s04e_26_cod	Entero	S4	Variable documentada en el diccionario Word †	96,6	96,6	1 a 97.000
177	s04e_27	Entero	S4	Variable documentada en el diccionario Word †	96,6	96,6	1 a 8
178	s04e_28	Entero	S4	Variable documentada en el diccionario Word †	99,7	99,7	1 a 5
179	s04e_29	Decimal	S4	Variable documentada en el diccionario Word †	96,6	96,6	1 a 7
180	s04e_30a	Entero	S4	Variable documentada en el diccionario Word †	96,6	96,6	1 a 15
181	s04e_30b	Entero	S4	Variable documentada en el diccionario Word †	96,6	96,6	0 a 45
182	s04f_31a	Entero	S4	Variable documentada en el diccionario Word †	99,7	99,7	30 a 7.000
183	s04f_31b	Entero	S4	Variable documentada en el diccionario Word †	99,7	99,7	1 a 8
184	s04f_32a	Entero	S4	Variable documentada en el diccionario Word †	99,7	99,7	1 / 2
185	s04f_32a1	Entero	S4	Variable documentada en el diccionario Word †	100,0	100,0	2.940 a 5.000
186	s04f_32b	Entero	S4	Variable documentada en el diccionario Word †	99,7	99,7	1 / 2
187	s04f_32b1	Entero	S4	Variable documentada en el diccionario Word †	100,0	100,0	2 a 1.000
188	s04f_32c	Entero	S4	Variable documentada en el diccionario Word †	99,7	99,7	1 / 2
189	s04f_32c1	Entero	S4	Variable documentada en el diccionario Word †	100,0	100,0	40 a 600
190	s04f_33a	Entero	S4	Variable documentada en el diccionario Word †	97,8	97,8	0 a 340.000
191	s04f_33b	Entero	S4	Variable documentada en el diccionario Word †	98,0	98,0	1 a 8
192	s04f_34a	Entero	S4	Variable documentada en el diccionario Word †	97,8	97,8	0 a 105.000
193	s04f_34b	Entero	S4	Variable documentada en el diccionario Word †	98,0	98,0	1 a 8
194	s04f_34ba	Entero	S4	Variable documentada en el diccionario Word †	99,1	99,1	1 / 2
195	s04f_34bb	Entero	S4	Variable documentada en el diccionario Word †	99,3	99,3	1 a 8
196	s04f_34bc	Entero	S4	Variable documentada en el diccionario Word †	99,3	99,3	3 a 11.000
197	s04f_35	Entero	S4	Variable documentada en el diccionario Word †	10,5	10,5	1 / 2
198	s04f_36	Entero	S4	Variable documentada en el diccionario Word †	86,0	86,0	1 / 2
199	s05a_01a	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	65,0	65,0	0 a 16.000
200	s05a_01b	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	86,9	86,9	0 a 350
201	s05a_01c	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	24,2	24,2	0 a 7.000
202	s05a_01d	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	10,5	10,5	0 a 5.200
203	s05a_01e	Entero	S5	Cobra Renta Dignidad (1 sí); universo: 60 años o más	86,9	86,9	1 / 2
204	s05a_01e0	Entero	S5	Monto de Renta Dignidad (Bs)	87,7	87,7	300 / 350
205	s05a_01f	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	87,7	87,7	1 / 2
206	s05a_02a	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	32,0	32,0	0 a 10.000

N.º	Variable	Tipo	Bloque	Descripción	% vac. orig.	% vac. final	Valores
207	s05a_02b	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	32,0	32,0	0 a 21.000
208	s05a_02c	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	32,0	32,0	0 a 6.000
209	s05a_02ce	Texto	S5	Texto libre «especifique»: Ingresos no laborales: jubilación, rentas, remesas †	99,9	99,9	texto (35)
210	s05a_03a	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	32,0	32,0	0 a 170.520
211	s05a_03b	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	32,0	32,0	0 a 50.000
212	s05a_03c	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	32,0	32,0	0 a 35.000
213	s05a_04a	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	24,2	24,2	0 a 100.000
214	s05a_04b	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	10,5	10,5	0 a 6.000
215	s05a_04c	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	32,0	32,0	0 a 525.000
216	s05a_04d	Entero	S5	Ingresos no laborales: jubilación, rentas, remesas †	10,5	10,5	0 a 30.000
217	s05b_05aa	Entero	S5	Bonos y transferencias del Estado †	0,1	0,1	0 a 5.000
218	s05b_05ab	Entero	S5	Bonos y transferencias del Estado †	97,1	97,1	2 a 8
219	s05b_05ba	Entero	S5	Bonos y transferencias del Estado †	0,1	0,1	0 a 13.500
220	s05b_05bb	Entero	S5	Bonos y transferencias del Estado †	95,6	95,6	2 a 8
221	s05b_05ca	Entero	S5	Bonos y transferencias del Estado †	0,1	0,1	0 a 6.000
222	s05b_05cb	Entero	S5	Bonos y transferencias del Estado †	95,5	95,5	2 a 8
223	s05b_06aa	Entero	S5	Bonos y transferencias del Estado †	0,0	0,0	0 a 7.140
224	s05b_06ab	Entero	S5	Bonos y transferencias del Estado †	99,6	99,6	4 / 8
225	s05b_06ae	Texto	S5	Texto libre «especifique»: Bonos y transferencias del Estado †	99,6	99,6	texto (60)
226	s05b_06ba	Entero	S5	Bonos y transferencias del Estado †	0,0	0,0	0 a 2.500
227	s05b_06bb	Entero	S5	Bonos y transferencias del Estado †	99,6	99,6	4 a 8
228	s05b_06be	Texto	S5	Texto libre «especifique»: Bonos y transferencias del Estado †	99,6	99,6	texto (30)
229	s05b_06ca	Entero	S5	Bonos y transferencias del Estado †	0,0	0,0	0 a 2.000
230	s05b_06cb	Entero	S5	Bonos y transferencias del Estado †	71,1	71,1	4 a 8
231	s05b_06ce	Texto	S5	Texto libre «especifique»: Bonos y transferencias del Estado †	71,1	71,1	texto (1275)
232	s05c_07	Entero	S5	Transferencias privadas e ingresos extraordinarios †	10,5	10,5	1 / 2
233	s05c_08	Entero	S5	Transferencias privadas e ingresos extraordinarios †	98,0	98,0	2 a 8
234	s05c_09a	Entero	S5	Transferencias privadas e ingresos extraordinarios †	98,0	98,0	0 a 500.000
235	s05c_09b	Entero	S5	Transferencias privadas e ingresos extraordinarios †	98,1	98,1	1 a 7
236	s05c_09e	Texto	S5	Texto libre «especifique»: Transferencias privadas e ingresos extraordinarios †	100,0	100,0	texto (1)
237	s05c_10	Entero	S5	Transferencias privadas e ingresos extraordinarios †	98,0	98,0	0 a 13.920
238	estrato	Entero	Viv	Estrato de diseño muestral	0,0	0,0	111 a 923
239	upm	Texto	Viv	Unidad primaria de muestreo	0,0	0,0	texto (1082)
240	factor	Decimal	Viv	Factor de expansión de la persona	0,0	0,0	18,35 a 3.407,91
241	cob_op	Entero	S4	Código de ocupación principal	50,7	50,7	0 a 9

N.º	Variable	Tipo	Bloque	Descripción	% vac. orig.	% vac. final	Valores
242	caeb_op	Entero	S4	Rama de actividad principal (CAEB)	50,7	50,7	0 a 20
243	caeb_os	Entero	S4	Rama de actividad secundaria (CAEB)	96,6	96,6	0 a 19
244	pet	Entero	S4	Población en edad de trabajar (1 si edad ≥ 14)	0,0	0,0	0 / 1
245	pea	Entero	S4	Población económicamente activa	10,5	10,5	0 / 1
246	pei	Entero	S4	Población económicamente inactiva	10,5	10,5	0 / 1
247	condact	Entero	S4	Condición de actividad (1 ocupado, 2 desocupado, 3 a 5 otras; solo 3 códigos documentados)	10,5	10,5	1 a 5
248	phrs	Decimal	S4	Horas semanales en la ocupación principal	50,7	50,7	1 a 171,50
249	shrs	Decimal	S4	Horas semanales en la ocupación secundaria	96,6	96,6	1 a 91
250	tothrs	Decimal	S4	Horas semanales totales (0 en no ocupados; máximo 112)	50,7	0,0	0 a 112
251	yprilab	Decimal	S4	Ingreso laboral de la ocupación principal	57,7	57,7	6,67 a 75.064,88
252	yseclab	Decimal	S4	Ingreso laboral de la ocupación secundaria	97,7	97,7	0 a 21.650
253	ylab	Decimal	S4	Ingreso laboral mensual (Bs); 0 en no ocupados; 2.490 imputados	57,7	0,0	0 a 82.270
254	ynolab	Decimal	S5	Ingreso no laboral mensual (Bs)	0,0	0,0	0 a 21.000
255	yper	Decimal	S5	Ingreso personal (ylab + ynolab)	0,0	0,0	0 a 97.270
256	yhog	Decimal	Viv	Ingreso total del hogar (suma de yper)	0,1	0,0	0 a 108.975
257	yhogpc	Decimal	Viv	Ingreso per cápita del hogar (yhog / totper)	0,1	0,0	0 a 39.358,67
258	z	Decimal	Viv	Línea de pobreza moderada (Bs)	0,0	0,0	761,84 a 1.228,81
259	zext	Decimal	Viv	Línea de pobreza extrema (Bs)	0,0	0,0	436,72 a 603,80
260	p0	Entero	Viv	Pobreza moderada: 1 si yhogpc < z	0,1	0,0	0 / 1
261	p1	Decimal	Viv	Brecha de pobreza moderada (FGT, α = 1)	0,1	0,1	0 a 1
262	p2	Decimal	Viv	Severidad de pobreza moderada (FGT, α = 2)	0,1	0,1	0 a 1
263	pext0	Entero	Viv	Pobreza extrema: 1 si yhogpc < zext	0,1	0,0	0 / 1
264	pext1	Decimal	Viv	Brecha de pobreza extrema (FGT, α = 1)	0,1	0,1	0 a 1
265	pext2	Decimal	Viv	Severidad de pobreza extrema (FGT, α = 2)	0,1	0,1	0 a 1
266	tipohogar	Entero	Viv	Tipo de hogar (códigos 1 a 7; 1 = unipersonal)	0,0	0,0	1 a 7
267	cobersalud	Entero	S2	Cobertura de seguro de salud (códigos 1 a 4; etiquetas por confirmar)	0,0	0,0	1 a 4
268	hnv_ult_a	Entero	S2	Hijos nacidos vivos en el último año	71,3	71,3	0 / 1
269	quienatenparto	Entero	S2	Personal que atendió el último parto	93,1	93,1	1 a 4
270	niv_ed	Entero	S3	Nivel educativo alcanzado (detallado)	5,4	5,4	0 a 6
271	niv_ed_g	Entero	S3	Nivel educativo alcanzado (agrupado)	5,4	5,4	0 a 4
272	cmasi	Entero	S3	Condición de asistencia escolar	5,4	5,4	1 a 3
273	educ_prev	Entero	S3	Nivel educativo previo	94,2	94,2	0 a 12
274	aestudio	Entero	S3	Años de estudio aprobados (0 en menores de 4 años)	5,4	0,0	0 a 23
275	sexo	Entero	S1	[Añadida] Sexo (copia explícita de s01a_02)	—	0,0	1 / 2
276	edad	Entero	S1	[Añadida] Edad en años (copia explícita de s01a_03)	—	0,0	0 a 98
277	parentesco	Entero	S1	[Añadida] Parentesco con el jefe/a (copia explícita de s01a_05)	—	0,0	1 a 14
278	tipo_na_embarazo	Texto	Clasif.	[Añadida] Clasificación del vacío de s02b_06 (Observado / NA_Estructural / NA_Real)	—	0,0	texto (2)
279	tipo_na_aestudio	Texto	Clasif.	[Añadida] Clasificación del vacío de aestudio	—	0,0	texto (2)
280	tipo_na_tothrs	Texto	Clasif.	[Añadida] Clasificación del vacío de tothrs	—	0,0	texto (2)
281	tipo_na_ylab	Texto	Clasif.	[Añadida] Clasificación del vacío de ylab	—	0,0	texto (3)
282	aestudio_imputado	Entero	Deriv.	[Añadida] Bandera: aestudio modificado (0 en toda la base)	—	0,0	0

N.º	Variable	Tipo	Bloque	Descripción	% vac. orig.	% vac. final	Valores
283	tothrs_imputado	Entero	Deriv.	[Añadida] Bandera: tothrs imputado (0 en toda la base)	—	0,0	0
284	ylab_imputado	Entero	Deriv.	[Añadida] Bandera: ylab imputado con PMM (2.490 casos)	—	0,0	0 / 1
285	totper	Entero	Viv	Total de personas del hogar (reconstruido por conteo)	0,1	0,0	1 a 15
286	cobersalud_imputado	Entero	Deriv.	[Añadida] Bandera: cobersalud imputado (0 en toda la base)	—	0,0	0
287	gasto_salud_total	Entero	Deriv.	[Añadida] Gasto de bolsillo en salud: suma de s02a_03a a s02a_03e (Bs)	—	0,0	0 a 112.450
288	uso_internet	Entero	Deriv.	[Añadida] Usa internet (1 sí), personas de 5 años o más	—	0,0	0 / 1
289	clima_educativo_hogar	Decimal	Deriv.	[Añadida] Promedio de años de estudio de los adultos del hogar	—	0,0	0 a 23
290	debajo_smn	Entero	Deriv.	[Añadida] 1 si ocupado a tiempo completo gana menos de Bs 2.500	—	0,0	0 / 1
291	ingreso_horario	Decimal	Deriv.	[Añadida] Ingreso laboral por hora (Bs)	—	0,0	0 a 2.167
292	subempleo_horario	Entero	Deriv.	[Añadida] 1 si ocupado trabaja menos de 40 horas	—	0,0	0 / 1
293	sobreempleo_horario	Entero	Deriv.	[Añadida] 1 si ocupado trabaja más de 48 horas	—	0,0	0 / 1
294	ynolab_imputado	Entero	Deriv.	[Añadida] Bandera: ynolab imputado (0 en toda la base)	—	0,0	0

Nota. Elaboración propia con base en *persona.csv*, *persona_limpio.csv*, *diccionario_final.csv*, *diccionario_corregido.csv* y *Diccionario de Persona.docx*. † = descripción por rango de cuestionario, tomada del diccionario Word y no verificada pregunta por pregunta.